

P121

MobileNets: redes convolucionales eficientes para visión en dispositivos móviles

MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications

Andrew G. Howard, Menglong Zhu, Bo Chen, Dmitry Kalenichenko, Weijun Wang, Tobias Weyand, Marco Andreetto, Hartwig Adam · 2017 · [arXiv:1704.04861](https://arxiv.org/abs/1704.04861)

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-18.

P121 — MobileNets

Ruta de percepción · Una convolución filtra el espacio y mezcla canales a la vez. Separarlas en dos pasos cuesta ocho veces menos y produce casi lo mismo.

Nivel: L2 · Motor: mobilenets · Notebook: P121_mobilenets.ipynb · Anexo: complejidad y coste

1. Identificación

Campo	Valor
Título original	MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications
Autoría	Andrew G. Howard, Menglong Zhu, Bo Chen, Dmitry Kalenichenko, Weijun Wang, Tobias Weyand, Marco Andreetto, Hartwig Adam
Año	2017
Venue	arXiv:1704.04861
Fuente primaria	arXiv:1704.04861
Acceso	Abierto
Fecha de consulta	2026-08-18

2. Problema anterior

Las redes de visión que funcionaban se habían construido suponiendo un centro de datos detrás. En un teléfono, una cámara de seguridad o un vehículo, el presupuesto es de milivatios y milisegundos, y hay que responder sin red.

El problema no era solo que las redes fueran grandes: era que **no había forma sistemática de elegir dónde recortar**. Cada equipo improvisaba su versión reducida, sin un marco que dijera qué se pierde por cada unidad de cómputo ahorrada.

3. Propuesta

Descomponer la convolución estándar en dos operaciones consecutivas:

1. **Convolución en profundidad**: un filtro espacial por canal, sin mezclarlos.
2. **Convolución puntual** de 1×1: mezcla los canales, sin mirar el espacio.

Juntas hacen lo mismo que una convolución estándar y cuestan una fracción. Y encima de eso, dos hiperparámetros globales que parametrizan la familia entera:

- **multiplicador de anchura** α : reduce los canales de todas las capas;

- **multiplicador de resolución** ρ : reduce el tamaño de la entrada.

Lo que se publica no es un modelo: es una **familia con dos perillas** donde el ingeniero elige el punto que le cabe.

4. Intuición sin fórmulas

Un taller donde cada operario corta y pinta cada pieza. Reorganizarlo en dos fases —unos cortan todas las piezas, otros las pintan— produce lo mismo con mucho menos trabajo repetido, porque cada especialista hace una sola cosa.

Dónde deja de funcionar la analogía: en el taller las dos fases son equivalentes al trabajo original. Aquí no del todo: la separación pierde algo de capacidad expresiva, y el artículo mide cuánto.

5. Matemática mínima

Convolución estándar : $k^2 \cdot M \cdot N \cdot S^2$
 Convolución separable : $k^2 \cdot M \cdot S^2 + M \cdot N \cdot S^2$
 ↓ profundidad ↓ puntual ↓
 razón = $1/N + 1/k^2$ ← con $k = 3$, el techo es $9 \times$

La miniatura mide una red de cinco capas:

	Millones de multiplicaciones
convolución estándar	935,7
convolución separable	111,1
razón	8,42×

La fórmula predice **0,1131** para 512 canales y la capa medida da **0,1131**. El término dominante es $1/k^2$, así que el ahorro **se satura cerca de 9×** por mucho que crezcan los canales: es un factor constante, no un orden de magnitud creciente.


El multiplicador de anchura da la segunda perilla, y el coste cae aproximadamente con α^2 :

α	Fracción del coste
0,75	0,574
0,50	0,265
0,25	0,075

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A05 §6 · La cuenta que casi nadie hace: inferencia	por qué el coste que importa en el borde es el de inferencia, y por qué contar operaciones no es contar tiempo

6. Arquitectura o flujo



7. Qué observar en el paper original

- La **tabla de compromisos**: exactitud frente a operaciones para cada valor de α y ρ . Es lo que convierte el artículo en una herramienta de decisión y no en un modelo más.
- El **reparto del cómputo por tipo de capa**: la mayor parte se va en las convoluciones de 1×1 , que además son las que mejor aprovecha el hardware.
- Los **casos de aplicación** que el artículo recorre —detección, geolocalización, atributos de rostro— para demostrar que la familia es de propósito general.
- La honestidad sobre el **techo del método**: el ahorro se satura, y el artículo lo dice en la propia fórmula.

8. Evidencia y resultados

Experimentos en ImageNet con la curva completa de exactitud frente a operaciones y frente a parámetros, más resultados en varias tareas derivadas.

Es la evidencia adecuada: no afirma ser el mejor modelo, sino ofrecer el mejor compromiso a presupuesto dado. Y lo demuestra con la curva, no con un punto.

La miniatura cuenta multiplicaciones-acumulaciones sobre una maqueta de cinco capas. No mide exactitud ni tiempo, que son la otra mitad del argumento.

9. Impacto

- La **convolución separable** es hoy estándar en cualquier arquitectura pensada para dispositivos, y aparece también en modelos grandes.

- Inauguró la línea de trabajo sobre arquitecturas eficientes: MobileNetV2 y V3, EfficientNet, y la búsqueda automática de arquitecturas bajo restricción de latencia.
- Hizo posible la visión por computador en el teléfono sin conexión, con las consecuencias de privacidad que eso tiene: los datos no salen del dispositivo.
- Y estableció la costumbre de **publicar una familia con perillas explícitas** en lugar de un único modelo, que es hoy la norma.

10. Limitaciones

1. **Contar operaciones no es medir tiempo.** La convolución en profundidad aprovecha peor la memoria que la estándar, y un modelo con $9\times$ menos operaciones puede ir solo $3\times$ más rápido.
2. **El ahorro tiene techo:** se satura cerca de k^2 , es decir $9\times$ con núcleos de 3×3 . No hay ganancia adicional por crecer.
3. **Hay pérdida de exactitud**, pequeña pero real, y crece según se aprieta α .
4. **Los multiplicadores son globales:** aplican el mismo recorte a todas las capas, cuando algunas toleran mucho más que otras. La búsqueda automática de arquitecturas lo resolvió después.
5. **No cubre la cuantización**, que en el borde suele aportar tanto como la arquitectura y es ortogonal a todo esto.

11. Errores comunes

Error	Corrección
«Menos operaciones significa proporcionalmente menos tiempo»	La convolución en profundidad aprovecha mucho peor la memoria. El ahorro medido en tiempo es bastante menor que el ahorro en operaciones.
«El ahorro crece con el número de canales»	El término dominante es $1/k^2$, no $1/N$. Con núcleos de 3×3 el ahorro se satura cerca de $9\times$ por muchos canales que haya.
«MobileNet es un modelo»	Es una familia parametrizada por dos multiplicadores. La aportación es la curva de compromisos, no un punto de ella.
«La separación es equivalente a la convolución estándar»	No del todo: pierde capacidad expresiva. El artículo mide cuánto, y es poco, pero no es cero.
«Para el borde basta con elegir una arquitectura eficiente»	La cuantización suele aportar tanto como la arquitectura, y es ortogonal. Este artículo no la cubre.

12. Relación con trabajos anteriores

- **P04 AlexNet (2012)** — la convolución estándar que aquí se descompone.
- **P45 Destilación (2015)** — la otra vía para reducir un modelo: transferir a uno pequeño en vez de rediseñarlo.
- **P44 ResNet (2015)** — la profundidad que hizo falta acotar cuando el presupuesto pasó a ser el problema.

13. Relación con trabajos posteriores

- **Sandler et al. (2018)** — MobileNetV2, con bloques residuales invertidos. [arXiv:1801.04381](https://arxiv.org/abs/1801.04381)

- **Jacob et al. (2018)** — cuantización entera para inferencia, la pieza que falta aquí. [arXiv:1712.05877](#)
- **Tan y Le (2019)** — EfficientNet: escalar anchura, profundidad y resolución de forma coordinada. [arXiv:1905.11946](#)

14. Notebook asociado

P121_mobilenets.ipynb

Qué implementa: el coste en multiplicaciones de la convolución estándar frente a la separable capa por capa, la comprobación de la fórmula $1/N + 1/k^2$, y cómo escala el coste con el multiplicador de anchura.

Qué NO implementa: se cuentan operaciones, no milisegundos, y no se mide exactitud. Las dos cosas son la otra mitad del argumento del artículo.

```
ai-evolution paper-lab P121 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe el coste de la convolución estándar y el de la separable.
Explicar	Explica por qué el ahorro tiene un techo.
Aplicar	Ejecuta el notebook y comprueba la fórmula contra la medición.
Analizar	Analiza por qué el ahorro en operaciones no se traduce en el mismo ahorro en tiempo.
Evaluar	«Bajamos las operaciones 9×, luego irá 9× más rápido». Evalúa la afirmación.
Crear	Calcula las multiplicaciones de un modelo que despliegues y estima el ahorro de separar sus convoluciones. Contrástalo con una medición real de latencia.

16. Autoevaluación

1. ¿En qué dos operaciones se descompone la convolución?
2. ¿Cuál es la fórmula del ahorro?
3. ¿Por qué se satura cerca de 9×?
4. ¿Qué hace el multiplicador de anchura?
5. ¿Por qué el ahorro en tiempo es menor que el ahorro en operaciones?
6. ¿Qué se publica exactamente en este artículo?
7. ¿Qué técnica complementaria no cubre?

17. Respuestas esperadas

1. Una convolución en profundidad —un filtro espacial por canal, sin mezclar— y una convolución puntual de 1×1 que mezcla los canales sin mirar el espacio.
2. $1/N + 1/k^2$, donde N son los canales de salida y k el tamaño del núcleo.

3. Porque el término dominante es $1/k^2$ y no depende de los canales. Con $k = 3$, el límite es $9\times$ por mucho que N crezca.
4. Reduce los canales de todas las capas por un factor α . El coste cae aproximadamente con α^2 : con $\alpha = 0,5$, al $0,265$ del total.
5. Porque la convolución en profundidad aprovecha mucho peor la localidad de memoria que la estándar, y el hardware está optimizado para la segunda.
6. Una familia de modelos parametrizada por dos multiplicadores, con la curva completa de exactitud frente a coste. No un modelo concreto.
7. La cuantización, que en el borde suele aportar tanto como la arquitectura y es ortogonal a la separación de convoluciones.

18. Fuentes primarias

- Howard, A. G. et al. (2017). *MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications*. **arXiv:1704.04861**. arxiv.org/abs/1704.04861 · consultado 2026-08-18.
- Sandler, M. et al. (2018). *MobileNetV2: Inverted Residuals and Linear Bottlenecks*. **arXiv:1801.04381** · consultado 2026-08-18.
- Jacob, B. et al. (2018). *Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference*. **arXiv:1712.05877** · consultado 2026-08-18.



Evaluación — P121 · MobileNets: redes convolucionales eficientes para visión en dispositivos móviles

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications* (2017, arXiv:1704.04861) · **Nivel:** L2

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P121_mobilenets.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).