

P126

Transformer de comprensión de documentos sin OCR

OCR-free Document Understanding Transformer

Geewook Kim, Teakgyu Hong, Moonbin Yim, JeongYeon Nam, Jinyoung Park, Jinyeong Yim, Wonseok Hwang,
Sangdoo Yun, Dongyoon Han, Seunghyun Park · 2022 · ECCV 2022, 498–517

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-18.

P126 — Donut

Ruta de percepción · Un OCR con 1 % de error por carácter suena excelente. Deja la mitad de los documentos con algún fallo, y el analizador no puede corregir ninguno.

Nivel: L3 · Motor: donut · Notebook: P126_donut.ipynb · Anexo: complejidad y coste

1. Identificación

Campo	Valor
Título original	OCR-free Document Understanding Transformer
Autoría	Geewook Kim, Teakgyu Hong, Moonbin Yim, JeongYeon Nam, Jinyoung Park y otros
Año	2022
Venue	ECCV 2022, 498–517
Fuente primaria	doi:10.1007/978-3-031-19815-1_29
Acceso	Restringido
Fecha de consulta	2026-08-18

2. Problema anterior

La tubería habitual para leer documentos tiene dos etapas: un OCR extrae el texto y un modelo lo interpreta. Esa arquitectura arrastra tres costes que se suelen contabilizar mal.

El primero es el que importa: **los errores del OCR llegan intactos al final y no hay quien los corrija**. Y no se suman, se **componen**: un error por carácter pequeño se convierte en una tasa de documentos correctos mucho peor, porque basta un fallo para estropear el documento entero.

Los otros dos son de operación: el OCR hay que licenciarlo y mantenerlo por idioma, y añade su propia latencia.

3. Propuesta

Eliminar la etapa: un modelo que va de **imagen a salida estructurada** directamente.

Un codificador visual procesa la imagen del documento y un decodificador emite la estructura —JSON, pares clave-valor, la respuesta a una pregunta— token a token. Nunca produce «el texto del documento» como paso intermedio.

Y una idea que resuelve el problema de datos: preentrenar con la tarea de **leer el documento completo** sobre imágenes sintéticas generadas con un motor tipográfico, que se pueden producir en cualquier idioma y en cualquier cantidad sin anotar nada a mano.

4. Intuición sin fórmulas

Una cadena de traducción donde el primer traductor pasa del japonés al inglés y el segundo del inglés al español. Si el primero se equivoca, el segundo traduce fielmente el error: no tiene el original delante para notarlo.

Un traductor que sepa japonés y español directamente comete sus propios errores, pero no hereda los de nadie.

Dónde deja de funcionar la analogía: el traductor directo hay que formarlo, y formarlo es más caro. Aquí igual: el modelo sin OCR necesita muchos más datos de entrenamiento que un analizador de texto.

5. Matemática mínima

Cascada: imagen —[OCR]→ texto —[analizador]→ estructura

$$P(\text{documento correcto}) = (1 - p)^{(\text{caracteres})} \quad \leftarrow \text{se COMPONE}$$

Sin OCR: imagen —————[modelo]————→ estructura

La miniatura simula 300 documentos de 6 campos y 9 caracteres cada uno —54 caracteres por documento—:



Error por carácter	Campos correctos	Documentos enteros
0,5 %	0,958	0,773
1 %	0,905	0,550
2 %	0,819	0,277
5 %	0,619	0,053

Un OCR del 99 % por carácter suena a objetivo cumplido y deja **la mitad** de los documentos con algún fallo. Y la medición sigue a la predicción: para el 1 %, la fórmula da **0,581** y se mide **0,550**. No es mala suerte, es aritmética de cascada.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A05 §8 · Checklist antes de creerte una cifra de rendimiento	por qué la unidad en la que se mide una tasa de error cambia por completo lo que la cifra significa

6. Arquitectura o flujo



7. Qué observar en el paper original

- El **generador de documentos sintéticos**, que es lo que hace viable el preentrenamiento sin anotación y en cualquier idioma. Es la mitad práctica del artículo.
- La comparación de **latencia y coste** frente a las tuberías con OCR, que en muchos casos pesa tanto como la exactitud.
- Que la salida es **estructura directamente**, no texto que luego alguien analiza. El decodificador emite JSON.
- Los experimentos en **varios idiomas**, incluido el coreano, que es donde la dependencia de un OCR comercial se nota más.

8. Evidencia y resultados

Comparación contra tuberías con OCR en extracción de información de recibos, clasificación y preguntas sobre documentos, con exactitud, latencia y coste.

La evidencia es completa porque incluye las tres dimensiones. Y conviene leerla con cuidado: el modelo sin OCR gana en unas tareas y no en todas, y necesita mucho más preentrenamiento.

La miniatura **no compara con Donut**: modela la aritmética de la cascada. Que quitar la etapa evite estos errores no demuestra que el modelo de extremo a extremo sea mejor — introduce los suyos, que sí son entrenables.

9. Impacto

- Abrió la línea de comprensión de documentos **sin OCR**, que hoy es la dirección dominante y la que siguen los modelos multimodales generales.
- Su generador de documentos sintéticos se reutilizó ampliamente para entrenar en idiomas sin recursos anotados.
- Nougat aplicó la misma idea a artículos científicos con fórmulas, donde el OCR clásico es especialmente malo.
- Y dejó una lección de medición que va más allá del área: **la unidad en la que declaras el error decide si tu sistema parece bueno o malo**, y hay que elegirla por lo que le importa al negocio.

10. Limitaciones

1. **Necesita mucho más preentrenamiento** que un analizador de texto: hay que aprender a leer desde cero en vez de reutilizar un OCR maduro.
2. **Sus errores no son diagnosticables**. En la cascada se puede señalar qué carácter leyó mal el OCR; aquí el fallo es del modelo entero.
3. **No gana en todas las tareas**, y el artículo lo muestra. Donde el OCR es muy bueno y el documento simple, la cascada sigue siendo competitiva.
4. **Los documentos muy largos o de alta resolución** son costosos para el codificador visual.
5. **El modelo sintético de errores de la miniatura es optimista**: supone errores independientes por carácter, y en la práctica van en ráfagas.

11. Errores comunes

Error	Corrección
«Un OCR con 99 % de exactitud por carácter es suficiente»	Sobre documentos de 54 caracteres deja el 55 % de documentos sin ningún fallo. La unidad que importa es el documento, no el carácter.
«Los errores del OCR se suman»	Se componen: $(1-p)$ elevado al número de caracteres. Por eso una tasa pequeña por carácter da una tasa grande por documento.
«El analizador puede corregir los errores del OCR»	Con contexto y validaciones recupera algunos, no todos, y no tiene el original delante para saber qué se leyó mal.
«Prescindir del OCR significa leer mejor»	Significa no heredar errores de una etapa incorregible. El modelo introduce los suyos, con la diferencia de que son entrenables.
«Sin OCR siempre es mejor»	El propio artículo muestra que no gana en todas las tareas. Con documentos simples y OCR bueno, la cascada sigue siendo competitiva.

12. Relación con trabajos anteriores

- **P125 LayoutLM (2020)** — la alternativa que sí usa OCR y añade la posición.
- **P46 Vision Transformer (2020)** — el codificador visual que hace viable procesar la imagen del documento.
- **P06 Secuencia a secuencia (2014)** — el patrón codificador- decodificador que aquí va de imagen a estructura.

13. Relación con trabajos posteriores

- **Blecher et al. (2023)** — Nougat: la misma idea sobre artículos científicos con fórmulas. [arXiv:2308.13418](#)
- **P18 CLIP (2021)** — la línea general de modelos que unen imagen y texto sin etapas intermedias.
- **P105 SeeClick (2024)** — leer una pantalla sin árbol de accesibilidad, que es el mismo argumento en otro dominio.

14. Notebook asociado

P126_donut.ipynb

Qué implementa: cómo se compone el error de un OCR a lo largo de un documento, medido en campos correctos y en documentos enteros correctos, y la comparación entre la predicción teórica y la medición.

Qué NO implementa: no se compara con Donut ni con ningún modelo: se modela la aritmética de la cascada. Y los errores se suponen independientes por carácter, cuando en la práctica van en ráfagas.

```
ai-evolution paper-lab P126 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la fórmula de la probabilidad de que un documento salga sin errores.
Explicar	Explica la diferencia entre medir en campos y medir en documentos.
Aplicar	Ejecuta el notebook y compara la predicción con la medición.
Analizar	Analiza qué gana y qué pierde un modelo sin etapa de OCR.
Evaluar	«Nuestro OCR tiene un 99 % de exactitud». Evalúa qué garantiza esa cifra.
Crear	Estima la tasa de error por carácter de tu OCR y calcula qué fracción de tus documentos sale limpia. Compárala con la que asume tu proceso.

16. Autoevaluación

1. ¿Por qué el error del OCR se compone?
2. ¿Qué fracción de documentos sobrevive a un 1 % de error por carácter?
3. ¿Qué gana un modelo sin OCR?
4. ¿Qué pierde?
5. ¿Cómo se preentrena sin datos anotados?
6. ¿Gana siempre la arquitectura sin OCR?
7. ¿En qué unidad conviene declarar el error?

17. Respuestas esperadas

1. Porque basta un carácter mal para estropear el documento entero: la probabilidad de acierto es $(1-p)$ elevado al número de caracteres, no una suma.
2. El 55 % en la miniatura, sobre documentos de 54 caracteres. Los campos correctos, en cambio, son el 90,5 %: la misma medición cuenta dos historias distintas.
3. Que no hereda errores de una etapa que no puede corregir, porque esa etapa no existe. También quita una licencia y una latencia.
4. Diagnosticabilidad: en la cascada se puede señalar qué leyó mal el OCR. Y necesita mucho más preentrenamiento, porque aprende a leer desde cero.
5. Generando documentos sintéticos con un motor tipográfico y entrenando con la tarea de leer el documento completo. Se producen en cualquier idioma y cantidad.
6. No. El propio artículo muestra que no gana en todas las tareas; con documentos simples y un OCR bueno, la cascada sigue siendo competitiva.
7. En la unidad que le importa a quien usa el sistema. Si el entregable es un documento procesado, declarar el error por carácter es engañoso.

18. Fuentes primarias

- Kim, G. et al. (2022). *OCR-free Document Understanding Transformer*. **ECCV 2022**, 498–517. doi:10.1007/978-3-031-19815-1_29 · consultado 2026-08-18.
- Blecher, L. et al. (2023). *Nougat: Neural Optical Understanding for Academic Documents*. arXiv:2308.13418 · consultado 2026-08-18.
- Xu, Y. et al. (2020). *LayoutLM*. doi:10.1145/3394486.3403172 · consultado 2026-08-18.



Evaluación — P126 · Transformer de comprensión de documentos sin OCR

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *OCR-free Document Understanding Transformer* (2022, ECCV 2022, 498–517) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P126_donut.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).