

P127

Jukebox: un modelo generativo de música

Jukebox: A Generative Model for Music

Prafulla Dhariwal, Heewoo Jun, Christine Payne, Jong Wook Kim, Alec Radford, Ilya Sutskever · 2020 ·
arXiv:2005.00341

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-18.

P127 — Jukebox

Ruta de medios · Cuatro minutos de canción son diez millones y medio de muestras. Antes de modelar hay que comprimir, y cuánto se comprime decide qué se puede aprender.

Nivel: L3 · Motor: `jukebox` · Notebook: `P127_jukebox.ipynb` · Anexo: complejidad y coste

1. Identificación

Campo	Valor
Título original	<i>Jukebox: A Generative Model for Music</i>
Autoría	Prafulla Dhariwal, Heewoo Jun, Christine Payne, Jong Wook Kim, Alec Radford, Ilya Sutskever
Año	2020
Venue	arXiv:2005.00341
Fuente primaria	arXiv:2005.00341
Acceso	Abierto
Fecha de consulta	2026-08-18

2. Problema anterior

WaveNet demostró que se puede modelar la forma de onda, pero a escala de segundos. Una canción son cuatro minutos: **más de diez millones de muestras** a 44,1 kHz, en estéreo.

Y no basta con comprimir. La música ocurre a escalas radicalmente distintas a la vez: el timbre se juega en milisegundos, el ritmo en décimas de segundo, la armonía en compases y la forma —estrofa, estribillo, puente— en minutos. Comprimir a una sola escala obliga a elegir cuál de esas cosas se conserva, y ninguna elección es buena.

3. Propuesta

Separar el problema en dos mitades y resolver cada una con lo suyo:

1. **Comprimir con un cuantizador vectorial jerárquico** (VQ-VAE) que codifica el audio en **tres niveles** de compresión distintos: 8×, 32× y 128×. Cada nivel produce una secuencia de códigos discretos, y cuanto más comprime, menos detalle guarda y más tiempo abarca.
2. **Modelar cada nivel con un Transformer autorregresivo**, empezando por el más grueso. Los niveles finos se generan **condicionados** por el grueso, así que no tienen que decidir la estructura: solo rellenar el detalle.

Y un condicionamiento adicional que es lo que hace el resultado memorable: artista, género y letra alineada, de modo que el modelo canta un texto dado con un estilo dado.

4. Intuición sin fórmulas

Dibujar un cuadro grande. Primero el boceto a carboncillo —la composición, dónde va cada cosa—, luego los volúmenes, y al final el detalle de la textura.

Si empiezas por el detalle, acabas con una esquina exquisita y un cuadro sin composición. La jerarquía impone el orden: lo que decide la forma se decide primero.

Dónde deja de funcionar la analogía: el pintor ve el lienzo entero mientras trabaja. Aquí ni el nivel más grueso abarca la canción completa, y esa es exactamente la limitación que le queda a Jukebox.

5. Matemática mínima

Cuantización vectorial: audio → secuencia de códigos de un diccionario finito
Jerarquía: tres niveles con factores de compresión 8×, 32× y 128×

Para cuatro minutos a 44,1 kHz —10 584 000 muestras—:

Nivel	Compresión	Códigos	Ventana de 8 192 abarca
superior	128×	82 687	23,8 s
medio	32×	330 750	5,9 s
inferior	8×	1 323 000	1,5 s


Dos lecturas. La primera: comprimir 128× cuesta fidelidad — el error de reconstrucción es 3,9× peor que a 8×. La segunda es el límite real del sistema: **ningún nivel cubre la canción**. El más grueso llega a 23,8 s de 240.

Hay que generar por ventanas solapadas, y por eso a Jukebox se le nota la falta de estructura a escala de pieza.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A05 §2 · El cruce: atención frente a recurrencia	por qué la longitud de la secuencia es lo que decide qué se puede modelar, y por qué comprimir es la única palanca

6. Arquitectura o flujo



7. Qué observar en el paper original

- El **alineamiento de la letra** con el audio, que es lo que permite que cante un texto concreto. Es un problema de atención sobre secuencias de longitudes muy distintas.
- Las **decisiones de entrenamiento del VQ-VAE**: colapso del diccionario, pérdida de compromiso, y todos los trucos que hacen falta para que la cuantización no degenera.
- La honestidad del artículo sobre la **falta de estructura a escala de canción**, que reconoce explícitamente como su limitación principal.
- La **sección sobre memorización**: los autores comprueban cuánto del entrenamiento reproduce el modelo, que es una pregunta que en música tiene consecuencias legales inmediatas.

8. Evidencia y resultados

El artículo aporta muestras generadas —muchas, y públicas—, mediciones de reconstrucción del VQ-VAE y un análisis de memorización.

La evidencia principal es perceptual y no cuantitativa: hay que escuchar. Eso es apropiado para el problema y a la vez difícil de comparar entre trabajos, que es una debilidad del área.

La miniatura no genera música: calcula la aritmética de la jerarquía y mide el compromiso entre compresión y fidelidad reconstruyendo una señal de juguete con la media de cada bloque. El error de un cuantizador entrenado es mucho menor.

9. Impacto

- Fue la primera demostración de que un modelo puede generar **canciones con voz cantada reconocible**, no solo texturas o melodías.
- Estableció la **jerarquía temporal** como la forma de abordar audio largo, idea que heredan AudioLM, MusicLM y MusicGen.
- Su cuantizador fue sustituido por códecs neuronales mejores —EnCodec, SoundStream— pero el patrón «comprimir a tokens discretos y modelar los tokens» es hoy universal en audio.
- Y puso sobre la mesa el problema de derechos: un modelo que imita a un artista concreto plantea preguntas que el artículo aborda pero no resuelve.

10. Limitaciones

1. **No hay estructura a escala de canción.** Ni el nivel grueso abarca la pieza, y generar por ventanas solapadas produce fragmentos coherentes que no forman un todo.
2. **Generar es lentísimo:** horas de cómputo por minuto de audio, lo que lo dejaba fuera de cualquier uso interactivo.
3. **La calidad de audio es limitada** por el cuantizador: se oyen artefactos característicos.
4. **La letra se entiende a medias.** El alineamiento funciona, pero la dicción es irregular.
5. **Imita artistas concretos**, lo que plantea un problema de derechos que el artículo reconoce sin resolver.

11. Errores comunes

Error	Corrección
«Con más capas o más datos se resolvería la estructura larga»	El límite es la ventana: ni el nivel grueso abarca la canción. Es un problema de representación, no de tamaño.
«Comprimir más es siempre mejor porque acorta la secuencia»	Cuesta fidelidad: en la miniatura, comprimir 128× da un error 3,9× peor que a 8×. Por eso hay tres niveles condicionados y no uno.
«Los tres niveles son tres calidades»	Son tres horizontes temporales. El grueso abarca 23,8 s y el fino 1,5 s con la misma ventana: sirven para cosas distintas.
«Jukebox genera música en tiempo real»	Tardaba horas por minuto de audio. La generación autorregresiva sobre secuencias largas era, y sigue siendo, cara.
«Que el modelo imite a un artista es un detalle técnico»	Es un problema de derechos que el propio artículo aborda, incluyendo un análisis de cuánto memoriza del entrenamiento.

12. Relación con trabajos anteriores

- **P119 WaveNet (2016)** — modelar audio en crudo, a escala de segundos.
- **P38 Autocodificador variacional (2013)** — la familia de la que desciende el cuantizador vectorial.
- **Po8 Transformer (2017)** — el modelo que se aplica a cada nivel de códigos.

13. Relación con trabajos posteriores

- **P129 MusicLM (2023)** — la misma jerarquía, con texto como condicionamiento y tokens semánticos.
- **Défossez et al. (2022)** — EnCodec: el códec neuronal que sustituyó a este cuantizador. [arXiv:2210.13438](#)
- **van den Oord et al. (2017)** — VQ-VAE, la cuantización vectorial original. [arXiv:1711.00937](#)

14. Notebook asociado

P127_jukebox.ipynb

Qué implementa: la aritmética de la jerarquía —cuántos códigos y cuánto tiempo abarca cada nivel con una ventana fija— y el compromiso medido entre factor de compresión y error de reconstrucción.

Qué NO implementa: no se genera música ni se entrena ningún cuantizador: la reconstrucción se hace promediando bloques, que es mucho peor que un VQ-VAE real.

```
ai-evolution paper-lab P127 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Describe los tres niveles de la jerarquía y para qué sirve cada uno.
Explicar	Explica por qué comprimir es obligatorio antes de modelar.
Aplicar	Ejecuta el notebook y comprueba cuánto tiempo abarca cada nivel.
Analizar	Analiza por qué ningún nivel cubre la canción y qué consecuencia tiene.
Evaluar	«Con una ventana mayor se arreglaría la estructura». Evalúa la afirmación.
Crear	Toma una pieza que conozcas y anota a qué escala temporal ocurre cada cosa que la hace reconocible. Compáralo con los tres niveles.

16. Autoevaluación

1. ¿Cuántas muestras son cuatro minutos a 44,1 kHz?
2. ¿Por qué tres niveles y no uno?
3. ¿Qué cuesta comprimir más?
4. ¿Cubre algún nivel la canción entera?
5. ¿Cómo se genera entonces una canción completa?
6. ¿Qué condicionamiento recibe el nivel superior?
7. ¿Cuál es la limitación que el artículo reconoce?

17. Respuestas esperadas

1. **10 584 000**. Ningún modelo autorregresivo opera sobre esa longitud, y por eso hay que comprimir antes de modelar.
2. Porque la música ocurre a escalas muy distintas: el timbre en milisegundos y la forma en minutos. Cada nivel es un horizonte temporal distinto, no una calidad distinta.
3. Fidelidad. En la miniatura, comprimir 128× da un error de reconstrucción 3,9× peor que comprimir 8×.
4. No. El más grueso abarca 23,8 s con una ventana de 8 192 códigos, y la canción dura 240.
5. Por ventanas solapadas. Eso produce fragmentos coherentes entre sí que no llegan a formar una estructura de pieza, y es la limitación principal.
6. Artista, género y la letra alineada con el audio. Eso es lo que permite que cante un texto concreto con un estilo dado.
7. La falta de estructura a escala de canción. Los autores lo dicen explícitamente en vez de dejarlo a que el lector lo note.

18. Fuentes primarias

- Dhariwal, P. et al. (2020). *Jukebox: A Generative Model for Music*. **arXiv:2005.00341**. arxiv.org/abs/2005.00341 · consultado 2026-08-18.
- van den Oord, A., Vinyals, O. y Kavukcuoglu, K. (2017). *Neural Discrete Representation Learning*. **arXiv:1711.00937** · consultado 2026-08-18.
- Défossez, A. et al. (2022). *High Fidelity Neural Audio Compression*. **arXiv:2210.13438** · consultado 2026-08-18.



Evaluación — P127 · Jukebox: un modelo generativo de música

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Jukebox: A Generative Model for Music* (2020, arXiv:2005.00341) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P127_jukebox.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).