

P131

Una marca de agua para modelos de lenguaje grandes

A Watermark for Large Language Models

John Kirchenbauer, Jonas Geiping, Yuxin Wen, Jonathan Katz, Ian Miers, Tom Goldstein · 2023 · ICML 2023 ·
arXiv:2301.10226

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español
que enlaza a la fuente primaria. Consultado 2026-08-18.

P131 — Una marca de agua

Ruta de medios · En vez de reconocer texto generado a posteriori —que falla—, dejar la marca al generar: sesgar qué tokens se eligen deja una firma estadística.

Nivel: L2 · **Motor:** `marcas_de_agua` · **Notebook:** `P131_marcas_de_agua.ipynb` · **Anexo:** probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	<i>A Watermark for Large Language Models</i>
Autoría	John Kirchenbauer, Jonas Geiping, Yuxin Wen, Jonathan Katz, Ian Miers, Tom Goldstein
Año	2023
Venue	ICML 2023 · arXiv:2301.10226
Fuente primaria	arXiv:2301.10226
Acceso	Abierto
Fecha de consulta	2026-08-18

2. Problema anterior

Distinguir texto generado de texto humano se venía intentando con **clasificadores entrenados a posteriori**, y ese enfoque tiene tres defectos que no se arreglan.

Envejecen: cada modelo nuevo los deja obsoletos. Producen **falsos positivos** con consecuencias reales —estudiantes acusados de copiar por un detector que se equivocó, y hablantes no nativos señalados desproporcionadamente. Y no dan ninguna garantía: son una conjetura estadística sobre un texto del que no se sabe nada.

El problema de fondo es que se intenta recuperar información que nunca se puso ahí.

3. Propuesta

Poner la información **al generar**, en lugar de intentar recuperarla después.

En cada paso de generación, un hash del token anterior parte el vocabulario en una lista **verde** —una fracción γ — y otra roja. Se añade un sesgo δ a los logits de la lista verde, de modo que el modelo tiende a elegir de ahí sin que el texto se degrade apreciablemente.

Detectar es entonces una prueba de hipótesis. Un texto no marcado tendrá alrededor de una fracción γ de tokens verdes; uno marcado, muchos más:

$$z = (\text{verdes} - \gamma n) / \sqrt{n \cdot \gamma (1 - \gamma)}$$

Y lo importante: **detectar no necesita el modelo, ni sus pesos, ni una clave privada**. Basta la función que define la lista verde.

4. Intuición sin fórmulas

Marcar billetes con un patrón acordado en vez de intentar adivinar por su aspecto si son falsos.

Adivinar por el aspecto se equivoca con billetes viejos y con falsificaciones buenas. La marca no se equivoca — con dos condiciones: que quien emite coopere, y que el billete no esté tan deteriorado que la marca ya no se lea.

Dónde deja de funcionar la analogía: la marca de un billete está en un sitio concreto. Aquí está repartida por todo el texto, así que un texto corto simplemente no tiene sitio donde llevarla.

5. Matemática mínima

En cada paso: hash(token anterior) → lista VERDE (fracción γ del vocabulario)
sesgar los logits verdes con δ

Detección: $z = (\text{verdes} - \gamma n) / \sqrt{n \cdot \gamma (1 - \gamma)}$

La miniatura usa $\gamma = 0,25$ y umbral $z = 4,0$:

	z media	Detectados
texto marcado (200 tokens)	4,83	25 de 30
texto no marcado	-0,13	0 de 30

Cero falsos positivos. Pero hay dos límites duros:


Longitud. Con 25 tokens la z media es **1,68** y se detecta **1 de 30**. Un tuit no se puede marcar: no hay suficiente texto para que la estadística diga nada.

Robustez. Reescribiendo el 30 % de los tokens, la detección cae a **2 de 30**; con el 50 %, a **0**. Parafrasear es un ataque barato.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A02 §5 · Estimadores, sesgo y varianza	de dónde sale la puntuación z y por qué necesita n grande para separar dos hipótesis

6. Arquitectura o flujo



7. Qué observar en el paper original

- Que la detección **no necesita el modelo**. Esa es la propiedad que la hace desplegable: un tercero puede verificar sin acceso a nadie.
- El compromiso del parámetro δ : sesgar más hace la marca más detectable y degrada más el texto. El artículo lo mide con perplejidad.
- El análisis de **qué pasa con texto de baja entropía**: si solo hay una continuación razonable, el modelo no puede permitirse sesgar, y ahí la marca no entra. Es un límite estructural.
- Las **variantes robustas** que el artículo propone para resistir edición, y sus límites.

8. Evidencia y resultados

Experimentos con modelos reales midiendo detectabilidad, tasa de falsos positivos y degradación de calidad por perplejidad, más un análisis de ataques por parafraseo.

La evidencia es completa y honesta con los límites: el propio artículo cuantifica cuánto texto hace falta y cuánto resiste la edición.

La miniatura usa un generador aleatorio en lugar de un modelo de lenguaje, así que **no mide la degradación de calidad**, que es la mitad del compromiso. Y el ataque simulado sustituye tokens al azar; un parafraseo con otro modelo es más eficaz.

9. Impacto

- Es el trabajo de referencia en marcado de texto generado, y el punto de partida de las implementaciones posteriores.
- **SynthID-Text** (Google, 2024) llevó la idea a producción a escala, con una variante que preserva mejor la calidad.
- Reorientó la discusión sobre procedencia: de **detectar** —que falla— a **marcar**, que es un problema tratable con condiciones claras.
- Y encaja con C2PA en imagen y vídeo, formando el enfoque general de procedencia declarada en el origen en lugar de inferida en el destino.

10. Limitaciones

1. **No funciona con texto corto.** Con 25 tokens se detecta 1 de 30. Un titular, un tuit o una respuesta breve no llevan marca útil.
2. **Parafrasear la borra.** Reescribir el 30 % de los tokens baja la detección a 2 de 30.
3. **Solo funciona si el generador coopera.** Un modelo de pesos abiertos se ejecuta sin marca, y basta con desactivarla.
4. **Degrada la calidad,** poco pero medible, y en texto de baja entropía la marca no puede entrar.
5. **Identifica al generador, no al autor ni la intención.** No dice si el texto es cierto, ni si quien lo publicó sabía que era generado.

11. Errores comunes

Error	Corrección
«La marca de agua resuelve la desinformación»	Identifica al generador, no la veracidad ni la intención. Un texto marcado puede ser cierto y uno sin marcar, falso.
«Sirve para cualquier texto»	Con 25 tokens se detecta 1 de 30. Hace falta longitud: un tuit no tiene sitio donde llevar la marca.
«Es robusta porque está repartida por todo el texto»	Reescribir el 30 % de los tokens baja la detección a 2 de 30. Parafrasear es un ataque barato y accesible.
«Detectar requiere acceso al modelo»	No: basta la función que define la lista verde. Esa es justamente la propiedad que la hace desplegable por terceros.
«Si todos los modelos la implementaran, el problema estaría resuelto»	Un modelo de pesos abiertos se ejecuta sin ella. La marca depende de que el generador coopere, y no todos cooperan.

12. Relación con trabajos anteriores

- **P10 GPT-3 (2020)** — el modelo cuya salida hay que poder identificar.
- **P130 VALL-E (2023)** — el mismo problema en voz, donde la urgencia es mayor.
- **P55 Teoría de la información (1948)** — la entropía que decide cuánta marca cabe en un texto.

13. Relación con trabajos posteriores

- **Dathathri et al. (2024)** — SynthID-Text, la variante desplegada en producción. doi:10.1038/s41586-024-08025-4
- **C2PA** — procedencia por metadatos firmados, el enfoque complementario en imagen y vídeo. c2pa.org
- **P133 Colapso de modelo (2024)** — por qué saber qué se generó importa para el corpus del modelo siguiente.

14. Notebook asociado

P131_marcas_de_agua.ipynb

Qué implementa: la puntuación z de texto marcado frente a no marcado con su tasa de falsos positivos, cuánto texto hace falta para detectar, y cómo se degrada la detección al reescribir una fracción de los tokens.

Qué NO implementa: el «modelo» es un generador aleatorio, así que no se mide la degradación de calidad —la mitad del compromiso—. Y el ataque sustituye tokens al azar; parafrasear con otro modelo es más eficaz.

```
ai-evolution paper-lab P131 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la fórmula de la puntuación z de detección.
Explicar	Explica por qué la detección no necesita el modelo.
Aplicar	Ejecuta el notebook y localiza a partir de cuántos tokens se detecta.
Analizar	Analiza por qué el parafraseo es un ataque eficaz.
Evaluar	«El texto lleva marca de agua, luego es falso». Evalúa la afirmación.
Crear	Define el umbral de detección que usarías en un caso tuyo y calcula la tasa de falsos positivos que aceptas. Razona qué le pasa a alguien acusado por uno.

16. Autoevaluación

1. ¿Qué determina la lista verde en cada paso?
2. ¿Qué necesita la detección?
3. ¿Cuánto texto hace falta?
4. ¿Qué le hace el parafraseo?
5. ¿Por qué falla con texto de baja entropía?
6. ¿Qué garantiza exactamente una marca detectada?
7. ¿Qué pasa con los modelos de pesos abiertos?

17. Respuestas esperadas

1. Un hash del token anterior. Eso hace la partición reproducible sin guardar nada, y distinta en cada posición.
2. Solo la función que define la lista verde. No hace falta el modelo, ni sus pesos, ni una clave privada, y por eso un tercero puede verificar.
3. Bastante. Con 25 tokens se detecta 1 de 30 y con 200, 25 de 30. Un texto corto no tiene sitio donde llevar la marca.
4. La borra. Reescribiendo el 30 % de los tokens la detección cae a 2 de 30; con el 50 %, a cero.
5. Porque si solo hay una continuación razonable, el modelo no puede permitirse sesgar sin estropear el texto. La marca necesita libertad de elección para entrar.
6. Que ese texto lo produjo un generador que coopera con el esquema. No dice si es cierto, ni cuál fue la intención, ni si quien lo publicó lo sabía.
7. Se ejecutan sin marca: basta desactivarla. El esquema depende de que el generador coopere.

18. Fuentes primarias

- Kirchenbauer, J. et al. (2023). *A Watermark for Large Language Models*. **ICML 2023**. arxiv.org/abs/2301.10226 · consultado 2026-08-18.
- Dathathri, S. et al. (2024). *Scalable watermarking for identifying large language model outputs*. [doi:10.1038/s41586-024-08025-4](https://doi.org/10.1038/s41586-024-08025-4) · consultado 2026-08-18.
- C2PA. *Content Credentials Specification 1.3*. c2pa.org · consultado 2026-08-18.



Evaluación — P131 · Una marca de agua para modelos de lenguaje grandes

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *A Watermark for Large Language Models* (2023, ICML 2023 · arXiv:2301.10226) · **Nivel:** L2

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P131_marcas_de_agua.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).