

P133

Los modelos de IA colapsan al entrenarse con datos generados recursivamente

AI models collapse when trained on recursively generated data

Ilia Shumailov, Zakhar Shumaylov, Yiren Zhao, Nicolas Papernot, Ross Anderson, Yarin Gal · 2024 · Nature, 631,
755–759

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-18.

P133 — Colapso de modelo

Ruta de medios · Treinta generaciones y ningún modelo comete un error: todos ajustan bien lo que reciben. Y aun así se pierden dos tercios de la variedad.

Nivel: L2 · **Motor:** colapso_de_modelo · **Notebook:** P133_colapso_de_modelo.ipynb · **Anexo:** probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	AI models collapse when trained on recursively generated data
Autoría	Ilia Shumailov, Zakhar Shumaylov, Yiren Zhao, Nicolas Papernot, Ross Anderson, Yarin Gal
Año	2024
Venue	Nature, 631, 755–759
Fuente primaria	doi:10.1038/s41586-024-07566-y
Acceso	Abierto
Fecha de consulta	2026-08-18

2. Problema anterior

Los corpus de entrenamiento se recogen de la web. La web se está llenando de texto e imágenes generadas por modelos. Los corpus futuros contendrán, sin que nadie lo decida, una fracción creciente de salidas de la generación anterior de modelos.

Nadie había caracterizado qué le ocurre a un modelo entrenado sobre lo que generó su antecesor, y la intuición común —«mientras la calidad sea buena, no pasa nada»— resultó estar equivocada por una razón que no tiene que ver con la calidad.

3. Propuesta

Formalizar y medir el fenómeno, al que llaman **colapso de modelo**, en tres familias distintas: modelos de lenguaje, autocodificadores variacionales y mezclas de gaussianas.

La tesis es que el colapso **no exige ningún fallo**. Basta el **error de muestreo**: cada generación ve un número finito de muestras de la anterior, y ese muestreo finito pierde sistemáticamente lo menos probable. Repetido, el efecto se acumula y la distribución converge a algo degenerado.

Distinguen dos fases: un **colapso temprano**, donde se pierden las colas, y uno **tardío**, donde la distribución se estrecha hasta perder casi toda su varianza.

4. Intuición sin fórmulas

Fotocopiar una fotocopia. Cada copia es fiel a la anterior —ninguna máquina falla— y a la vigésima el documento es ilegible.

Lo que se pierde primero es el detalle fino, lo que estaba al límite de la resolución. Y no hay ninguna copia concreta donde el fallo ocurriera.

Dónde deja de funcionar la analogía: la fotocopia degrada por ruido físico. Aquí el mecanismo es puramente estadístico: cada generación estima **bien** los parámetros de la anterior. Es más inquietante, porque no hay nada que arreglar en el proceso.

5. Matemática mínima

Generación g: ajustar un modelo a n muestras de la generación g-1, y muestrear de él

El estimador de la varianza con n muestras encoge por un factor $\sqrt{1 - 1/n}$ cada vez.

Repetido g veces: $\sigma_g \approx \sigma_0 \cdot (1 - 1/n)^{(g/2)}$

La miniatura usa 25 muestras por generación y 30 generaciones:

	Inicial	Tras 30 generaciones
desviación	0,793	0,252 (31,8 %)
rango	2,856	0,880 (3,2× menor)
media	-0,087	-1,447


Hay **dos** efectos, no uno. La distribución **se estrecha** —lo esperado— y además **deriva**: la media hace un paseo aleatorio del que ninguna generación puede darse cuenta, porque cada una ajusta perfectamente los datos que recibe.

Y el remedio se mide: conservar un **25 %** de datos reales en cada generación deja la desviación final en **0,806** frente a 0,252 sin ninguno.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A02 §5 · Estimadores, sesgo y varianza	por qué el estimador de la varianza con n muestras encoge, y qué pasa al aplicarlo treinta veces seguidas

6. Arquitectura o flujo



7. Qué observar en el paper original

- Que el resultado se demuestra en **tres familias de modelos** distintas. Eso es lo que convierte una observación en un fenómeno general.
- La distinción entre **colapso temprano** —se pierden las colas— y **tardío** —se pierde casi toda la varianza—. Son fases con síntomas distintos.
- El **análisis teórico** para el caso gaussiano, que da la tasa de encogimiento y permite predecir cuántas generaciones aguanta un proceso.
- La discusión sobre la **procedencia de los datos** como bien común: si nadie registra qué es generado, nadie puede protegerse.

8. Evidencia y resultados

Experimentos en modelos de lenguaje —con ejemplos de degeneración textual muy elocuentes—, autocodificadores variacionales y mezclas de gaussianas, más análisis teórico del caso tratable.

Publicado en *Nature*, con revisión y datos disponibles. La combinación de teoría en el caso simple y medición en los complejos es la forma correcta de sostener una tesis así.

La miniatura usa una gaussiana ajustada por momentos. Reproduce el mecanismo —error de muestreo acumulado— pero no la riqueza del fenómeno en modelos reales, donde además interactúa con la arquitectura.

9. Impacto

- Puso nombre a un riesgo sistémico del que se hablaba de forma vaga, y lo convirtió en algo medible.
- Dio valor económico y estratégico a los **corpus anteriores a la IA generativa**, y a los datos con procedencia verificada.
- Refuerza el argumento de las marcas de agua: sin saber qué es generado, no se puede controlar la proporción.
- Y matizó el entusiasmo por los datos sintéticos, que hasta entonces se presentaban como solución general a la escasez de datos.

10. Limitaciones

1. **El escenario es el peor caso:** cada generación entrena **solo** con lo generado. En la práctica los corpus se contaminan parcialmente.

2. **Trabajos posteriores matizan el resultado.** Si los datos se **acumulan** en lugar de reemplazarse, el colapso se atenúa mucho.
3. **No modela el filtrado por calidad.** Si alguien selecciona las mejores salidas para reentrenar, el efecto cambia — y puede estrechar aún más la distribución.
4. **La escala de los experimentos** es modesta comparada con los modelos de frontera.
5. **No dice qué proporción de datos sintéticos es segura**, que es la pregunta que un equipo necesita responder.

11. Errores comunes

Error	Corrección
«El colapso ocurre porque los modelos cometen errores»	No: cada generación estima bien los parámetros de la anterior. Basta el error de muestreo acumulado, sin ningún fallo.
«Si la calidad de las salidas es buena, no hay problema»	La calidad media puede mantenerse mientras la variedad desaparece. En la miniatura queda el 31,8 % de la desviación original.
«Es lo mismo que un sobreajuste»	El sobreajuste es memorizar el conjunto de entrenamiento. Aquí cada generación generaliza bien; lo que se pierde es la distribución de la que se muestreó.
«Solo se estrecha la distribución»	También deriva: en la miniatura la media pasa de $-0,087$ a $-1,447$. Ese paseo aleatorio es indetectable desde dentro de cualquier generación.
«Basta con dejar de usar datos sintéticos»	El problema es no SABER que los estás usando. Sin procedencia registrada no puedes medir tu proporción ni conservar datos reales a propósito.

12. Relación con trabajos anteriores

- **P131 Una marca de agua (2023)** — el mismo problema visto desde el otro lado: saber qué se generó.
- **P61 Loros estocásticos (2021)** — qué hay dentro de los corpus y qué no se sabe de ellos.
- **P115 Hojas de datos (2021)** — la documentación de procedencia que aquí se vuelve imprescindible.

13. Relación con trabajos posteriores

- **Gerstgrasser et al. (2024)** — qué cambia si los datos se acumulan en lugar de reemplazarse. [arXiv:2404.01413](#)
- **Alemohammad et al. (2023)** — el mismo fenómeno en modelos de imagen. [arXiv:2307.01850](#)
- **P19 Leyes de escalado (2022)** — el presupuesto de datos que este fenómeno pone en cuestión.

14. Notebook asociado

`P133_colapso_de_modelo.ipynb`

Qué implementa: la evolución de la desviación, el rango y la media a lo largo de treinta generaciones entrenando solo con lo generado, y el efecto de conservar una fracción de datos reales.

Qué NO implementa: el modelo es una gaussiana ajustada por momentos, no una red, y cada generación entrena SOLO con lo generado. En la práctica la contaminación es parcial y el ritmo depende de esa proporción.

```
ai-evolution paper-lab P133 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Explica qué es el colapso de modelo.
Explicar	Describe por qué no exige ningún fallo del modelo.
Aplicar	Ejecuta el notebook y observa las dos magnitudes que cambian.
Analizar	Analiza por qué la deriva de la media es indetectable desde dentro.
Evaluar	«Las salidas siguen siendo de buena calidad, luego no hay colapso». Evalúa la afirmación.
Crear	Estima qué fracción de tus datos de entrenamiento podría ser generada. Si no puedes estimarla, escribe qué registro te haría falta.

16. Autoevaluación

1. ¿Qué mecanismo produce el colapso?
2. ¿Qué se pierde primero?
3. ¿Cuántos efectos hay, y cuáles?
4. ¿Se puede detectar desde dentro de una generación?
5. ¿Qué lo frena?
6. ¿En qué se diferencia del sobreajuste?
7. ¿Qué matizan los trabajos posteriores?

17. Respuestas esperadas

1. El error de muestreo acumulado. Cada generación ve un número finito de muestras de la anterior, y ese muestreo pierde sistemáticamente lo menos probable.
2. Las colas: lo raro es lo que menos se muestrea. En la miniatura el rango se estrecha $3,2\times$ a lo largo de treinta generaciones.
3. Dos. La distribución se **estrecha** —la desviación cae al 31,8 %— y además **deriva**: la media pasa de $-0,087$ a $-1,447$.
4. No. Cada generación ajusta perfectamente los datos que recibe y no tiene con qué comparar. Solo la distribución original, que ya nadie tiene, revelaría el desplazamiento.
5. Conservar datos reales. Con un 25 % de muestras reales por generación, la desviación final es $0,806$ frente a $0,252$ sin ninguna.
6. El sobreajuste es memorizar el conjunto de entrenamiento. Aquí cada generación generaliza bien; lo que se degrada es la distribución de la que se muestrea.

7. Que si los datos se acumulan en vez de reemplazarse, el colapso se atenúa mucho. El escenario del artículo es el peor caso.

18. Fuentes primarias

- Shumailov, I. et al. (2024). *AI models collapse when trained on recursively generated data*. **Nature**, 631, 755–759. doi:10.1038/s41586-024-07566-y · consultado 2026-08-18.
- Gerstgrasser, M. et al. (2024). *Is Model Collapse Inevitable?* arXiv:2404.01413 · consultado 2026-08-18.
- Alemohammad, S. et al. (2023). *Self-Consuming Generative Models Go MAD*. arXiv:2307.01850 · consultado 2026-08-18.



Evaluación — P133 · Los modelos de IA colapsan al entrenarse con datos generados recursivamente

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *AI models collapse when trained on recursively generated data* (2024, Nature, 631, 755–759) ·

Nivel: L2

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P133_colapso_de_modelo.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).