

P141

El problema de las dos sigmas: buscar instrucción grupal tan eficaz como la tutoría individual

The 2 Sigma Problem: The Search for Methods of Group Instruction as Effective as One-to-One Tutoring

Benjamin S. Bloom · 1984 · Educational Researcher, 13(6), 4–16

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-18.

P141 — El problema de las dos sigmas

Ruta de gobernanza · La tutoría uno a uno mueve al alumno medio dos desviaciones. Y exige un docente por alumno: el hallazgo no es la tutoría, es el problema.

Nivel: L1 · Motor: dos_sigma · Notebook: P141_dos_sigma.ipynb · Anexo: probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	<i>The 2 Sigma Problem: The Search for Methods of Group Instruction as Effective as One-to-One Tutoring</i>
Autoría	Benjamin S. Bloom
Año	1984
Venue	Educational Researcher, 13(6), 4–16
Fuente primaria	doi:10.2307/1175554
Acceso	Restringido
Fecha de consulta	2026-08-18

2. Problema anterior

Que la tutoría individual funciona mejor que una clase de treinta lo sabía cualquiera. Lo que no había era una **medida comparable**: los estudios reportaban diferencias en puntos de exámenes distintos, en asignaturas distintas, y no se podían sumar ni contrastar.

Sin esa medida no se podía formular la pregunta interesante, que no es si la tutoría funciona sino **cuánto se pierde por no poder pagarla** —y si hay alguna forma de recuperarlo sin un docente por alumno—.

3. Propuesta

Medir el efecto en **desviaciones típicas** de la distribución de la clase convencional. Eso hace comparables estudios de asignaturas y exámenes distintos, y es lo que hoy se llama *tamaño del efecto*.

Con esa medida, los resultados que Bloom sintetiza son:

- tutoría uno a uno: $+2\sigma$
- aprendizaje para el dominio —corregir antes de avanzar, en grupo—: $+1\sigma$

Y con eso formula el problema que da título al artículo: encontrar métodos de instrucción **grupal** tan eficaces como la tutoría. No es un resultado, es una **agenda de investigación**.

4. Intuición sin fórmulas

Una carrera donde el corredor medio del grupo entrenado individualmente llega antes que el 97 % del grupo con entrenador compartido.

Nadie duda de que el entrenamiento individual es mejor. La pregunta útil es qué parte de esa ventaja viene de cosas que sí se pueden dar en grupo —corregir antes de seguir, no avanzar hasta dominar— y qué parte exige irreductiblemente una persona por alumno.

Dónde deja de funcionar la analogía: en la carrera el resultado es objetivo. En educación, qué se mide en el examen determina qué método parece mejor, y eso es parte del problema.

5. Matemática mínima

$$\text{tamaño del efecto} = (\text{media del grupo tratado} - \text{media del control}) / \text{desviación del control}$$

La miniatura simula las tres condiciones con 400 alumnos cada una:

Condición	Desplazamiento	Supera al alumno medio convencional
clase convencional	0 σ	52,2 %
aprendizaje para el dominio	+1 σ	85,0 %
tutoría uno a uno	+2 σ	97,5 %

Y el coste, que es la otra mitad del argumento:


Condición	Docentes para 400 alumnos
clase convencional	14
aprendizaje para el dominio	14
tutoría uno a uno	400

El aprendizaje para el dominio consigue **la mitad del efecto con el coste de la clase convencional**. Esa es la parte aplicable, y la que Bloom recomienda.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A02 §5 · Estimadores, sesgo y varianza	por qué normalizar por la desviación permite comparar estudios que miden cosas distintas

6. Arquitectura o flujo



7. Qué observar en el paper original

- Que el artículo es una **agenda**, no un resultado: pide encontrar métodos grupales, y enumera variables candidatas ordenadas por su tamaño de efecto.
- La tabla de **variables alterables**: refuerzo, corrección, participación del alumno, tiempo dedicado. Es lo que se puede manipular, frente a lo que no.
- La advertencia del propio Bloom sobre la **duración corta** de los estudios y su restricción a asignaturas concretas. La cifra se cita con más confianza de la que él pide.
- El **aprendizaje para el dominio** como la propuesta concreta: no avanzar hasta dominar, con evaluación formativa y corrección. Es lo aplicable hoy.

8. Evidencia y resultados

Es una síntesis de estudios propios y de sus doctorandos, con tamaños de efecto medidos en condiciones controladas.

La cifra de 2 σ procede de un número reducido de estudios, cortos y en asignaturas concretas. Réplicas y síntesis posteriores encuentran efectos bastante menores: VanLehn (2011) sitúa los tutores inteligentes cerca de 0,76 σ.

La miniatura no reproduce ningún estudio: simula tres distribuciones con los desplazamientos que el artículo reporta, para exhibir qué significa «dos sigmas» expresado en fracción de alumnos.

9. Impacto

- Popularizó el **tamaño del efecto** en investigación educativa, lo que hizo comparables décadas de estudios dispersos.
- El **aprendizaje para el dominio** influyó en el diseño curricular y sigue siendo la base de los sistemas de progresión por competencia.
- Es la referencia obligada de cualquier propuesta de **tutoría automatizada**, incluidas las actuales con modelos de lenguaje: la promesa que se hace es literalmente cerrar el hueco que Bloom describió.
- Y aporta al programa el hábito de exigir el tamaño del efecto y la línea base antes de aceptar que una herramienta educativa funciona.

10. Limitaciones

1. **La cifra de 2σ está sobrecitada.** Procede de pocos estudios, cortos, y las réplicas encuentran efectos menores.
2. **Los estudios miden exámenes de contenido**, no capacidades a largo plazo ni transferencia.
3. **No dice qué hace un tutor** que produzca el efecto: adaptar el ritmo, detectar el malentendido, motivar. Sin eso, no está claro qué habría que automatizar.
4. **El contexto es de 1984**, con una organización escolar concreta.
5. **Un tamaño de efecto no distingue** entre aprender más y aprender a aprobar el examen que se usó para medirlo.

11. Errores comunes

Error	Corrección
«Dos sigmas es una constante bien establecida»	Procede de pocos estudios cortos, y el propio Bloom lo advierte. VanLehn mide los tutores inteligentes cerca de $0,76\sigma$.
«El artículo demuestra que hay que dar tutoría individual»	Demuestra que no se puede: 400 docentes para 400 alumnos. El artículo formula el problema de conseguir su efecto en grupo.
«Si una herramienta educativa mejora las notas, funciona»	Depende del tamaño del efecto y de la línea base. Sin las dos cifras, «mejora las notas» no es comparable con nada.
«El aprendizaje para el dominio es una versión pobre de la tutoría»	Consigue la mitad del efecto con el coste de una clase normal. Es la parte desplegable, y es lo que Bloom recomienda.
«Automatizar la tutoría es replicar lo que hace un tutor»	El artículo no dice qué hace un tutor para producir el efecto. Sin ese análisis, no está claro qué se está replicando.

12. Relación con trabajos anteriores

- **P60 Por qué la mayoría de los hallazgos publicados son falsos (2005)** — posterior, pero el criterio con el que hay que leer una síntesis de estudios cortos.
- **P56 Computing Machinery and Intelligence (1950)** — la otra pregunta sobre qué significa que una máquina enseñe o entienda.

13. Relación con trabajos posteriores

- **VanLehn (2011)** — cuánto consiguen realmente los sistemas de tutoría inteligente. doi:10.1080/00461520.2011.611369
- **Hattie (2008)** — síntesis de tamaños de efecto en educación. doi:10.4324/9780203887332
- **P148 Cerrar la brecha de responsabilidad (2020)** — qué hay que documentar antes de desplegar un sistema que decide sobre personas.

14. Notebook asociado

P141_dos_sigma.ipynb

Qué implementa: qué fracción de alumnos supera al alumno medio convencional en cada condición, y cuántos docentes exige cada una para el mismo número de alumnos.

Qué NO implementa: las distribuciones son gaussianas simuladas con los desplazamientos que reporta el artículo. No se reproduce ningún estudio ni se modela nada de lo que hace un tutor.

```
ai-evolution paper-lab P141 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Define tamaño del efecto.
Explicar	Explica por qué se mide en desviaciones típicas.
Aplicar	Ejecuta el notebook y compara las tres condiciones.
Analizar	Analiza por qué el aprendizaje para el dominio es la parte aplicable.
Evaluar	«Nuestra herramienta consigue 2 sigmas». Evalúa qué habría que comprobar.
Crear	Busca el tamaño del efecto de una herramienta educativa que conozcas y comprueba contra qué línea base lo declara.

16. Autoevaluación

1. ¿Qué es el problema de las dos sigmas?
2. ¿Por qué se mide en desviaciones típicas?
3. ¿Qué consigue el aprendizaje para el dominio?
4. ¿Cuál es el coste de la tutoría?
5. ¿Qué advertencia hace el propio Bloom?
6. ¿Qué NO dice el artículo?
7. ¿Cómo se relaciona con la IA educativa?

17. Respuestas esperadas

1. Encontrar métodos de instrucción **grupal** tan eficaces como la tutoría uno a uno. No es un resultado: es la agenda que el artículo propone.
2. Para poder comparar estudios de asignaturas y exámenes distintos. Es lo que hoy se llama tamaño del efecto.
3. Aproximadamente una desviación —la mitad del efecto de la tutoría— con el coste de una clase convencional. Es la parte desplegable.
4. Un docente por alumno: 400 para 400 alumnos frente a 14. Por eso el problema es de ingeniería educativa y no de convicción.
5. Que los estudios eran cortos y en asignaturas concretas. La cifra se cita con más confianza de la que él pide.
6. Qué hace exactamente un tutor para producir el efecto. Sin ese análisis no está claro qué habría que automatizar.
7. Es la promesa que se le hace: cerrar el hueco entre la clase y la tutoría. Conviene exigir tamaño de efecto y línea base antes de crearla.

18. Fuentes primarias

- Bloom, B. S. (1984). *The 2 Sigma Problem*. **Educational Researcher**, 13(6), 4–16.
doi:10.2307/1175554 · consultado 2026-08-18.
- VanLehn, K. (2011). *The Relative Effectiveness of Human Tutoring, Intelligent Tutoring Systems, and Other Tutoring Systems*. doi:10.1080/00461520.2011.611369 · consultado 2026-08-18.
- Hattie, J. (2008). *Visible Learning*. doi:10.4324/9780203887332 · consultado 2026-08-18.



Evaluación — P141 · El problema de las dos sigmas: buscar instrucción grupal tan eficaz como la tutoría individual

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *The 2 Sigma Problem: The Search for Methods of Group Instruction as Effective as One-to-One Tutoring* (1984, Educational Researcher, 13(6), 4–16) · **Nivel:** L1

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P141_dos_sigma.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).