

P143

Calibrar el ruido a la sensibilidad en el análisis privado de datos

Calibrating Noise to Sensitivity in Private Data Analysis

Cynthia Dwork, Frank McSherry, Kobbi Nissim, Adam Smith · 2006 · TCC 2006, 265–284

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-18.

P143 — Calibrar el ruido a la sensibilidad

Ruta de gobernanza · Dos consultas que difieren en una persona. La resta revela su dato con certeza.
Publicar agregados exactos no protege a nadie.

Nivel: L3 · **Motor:** privacidad_diferencial · **Notebook:** P143_privacidad_diferencial.ipynb · **Anexo:** probabilidad y verosimilitud

1. Identificación

Campo	Valor
Título original	Calibrating Noise to Sensitivity in Private Data Analysis
Autoría	Cynthia Dwork, Frank McSherry, Kobbi Nissim, Adam Smith
Año	2006
Venue	TCC 2006, 265–284
Fuente primaria	doi:10.1007/11681878_14
Acceso	Restringido
Fecha de consulta	2026-08-18

2. Problema anterior

La anonimización fallaba una y otra vez. Quitar el nombre y el documento de identidad no impide reidentificar a alguien cruzando el conjunto con otra fuente: se demostró con historiales médicos, con datos de taxis, con valoraciones de películas.

El problema no era que las técnicas fueran malas. Era **la definición**: cualquier noción de privacidad basada en «quitar los identificadores» depende de qué **más** sepa quien ataca, y eso no se puede acotar ni conocer.

Hacía falta una definición que no dependiera del conocimiento auxiliar del atacante.

3. Propuesta

Cambiar el objeto de la definición: la privacidad deja de ser una propiedad **del dato publicado** y pasa a ser una propiedad **del mecanismo que lo publica**.

M es ϵ -diferencialmente privado $\Leftrightarrow$ para todo par de bases D, D' que difieren en UNA persona, y todo conjunto de resultados S :

$$P[M(D) \in S] \leq e^{\epsilon} \cdot P[M(D') \in S]$$

Es decir: que estés o no estés en la base **casi no cambia** lo que sale. Si la salida es prácticamente la misma contigo y sin ti, no se puede deducir nada sobre ti — con independencia de lo que el atacante sepa por otro lado.

Y un mecanismo que la cumple: añadir **ruido de Laplace** de escala `sensibilidad / ε`, donde la sensibilidad es cuánto puede cambiar el resultado por una sola persona.

4. Intuición sin fórmulas

Una encuesta sobre algo embarazoso donde, antes de responder, cada persona lanza una moneda en secreto: si sale cara responde la verdad, si sale cruz responde al azar.

Nadie puede deducir tu respuesta individual, porque siempre puedes decir que te salió cruz. Y con suficientes respuestas, el porcentaje agregado sigue siendo estimable.

Dónde deja de funcionar la analogía: la moneda protege una respuesta. La privacidad diferencial protege contra **cualquier** consulta y **cualquier** conocimiento previo, y su garantía se degrada al hacer muchas preguntas — algo que la moneda no captura.

5. Matemática mínima

Sensibilidad $\Delta f = \max |f(D) - f(D')|$ sobre bases que difieren en una persona
Mecanismo: $M(D) = f(D) + \text{Laplace}(\Delta f / \epsilon)$

La miniatura ataca un conteo sobre 1 000 personas con dos consultas que solo difieren en una:

ε	Escala del ruido	Error medio	Acierto del ataque
sin ruido	0	0	100 %
10,0	0,1	0,10	99,3 %
1,0	1,0	0,99	56,5 %
0,1	10,0	9,95	48,2 %

Con $\epsilon = 0,1$ el ataque es indistinguible de adivinar. Con $\epsilon = 10$ **sigue acertando el 99,3 %** — cumpliendo la definición formal.

Ese es el punto que hay que ver: **el parámetro ES la garantía**. «Usamos privacidad diferencial» no es una afirmación verificable sin el valor de ϵ , y elegirlo es una decisión de política.

Y lo que se paga es exactitud: un error medio de 9,95 sobre un conteo de 249 es un 4 % relativo.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A02 §4 · Divergencia KL	cómo se mide la diferencia entre dos distribuciones: la definición acota exactamente esa razón para las bases con y sin una persona

6. Arquitectura o flujo



7. Qué observar en el paper original

- Que la garantía es **sobre el mecanismo**, no sobre el dato. Ese cambio de objeto es la aportación conceptual y lo que la hace robusta frente al conocimiento auxiliar.
- La noción de **sensibilidad** y por qué es la cantidad correcta a la que calibrar el ruido: mide cuánto puede cambiar la salida por una persona.
- Las propiedades de **composición**: hacer varias consultas gasta presupuesto de privacidad. Es lo que hace el marco utilizable y también lo que lo complica en la práctica.
- Que el artículo es de **criptografía**, con demostraciones formales. Su rigor es lo que permitió que la definición se convirtiera en estándar.

8. Evidencia y resultados

Es un artículo teórico: define, demuestra que el mecanismo cumple la definición y analiza la composición. No hay experimentos porque no los necesita.

Es evidencia matemática, y por eso la garantía es incondicional: no depende de supuestos sobre el atacante. Es una forma de evidencia distinta —y más fuerte— que un experimento.

La miniatura mide **una sola consulta**. La garantía real se degrada al hacer muchas, y administrar ese presupuesto es el problema práctico que el artículo formaliza y que la maqueta no toca.

9. Impacto

- Es el fundamento de la privacidad moderna en análisis de datos, con premio Gödel y adopción en productos reales.
- El **Censo de Estados Unidos de 2020** se publicó con privacidad diferencial, la primera aplicación a esa escala y con toda la polémica que generó.
- Apple, Google y Microsoft la usan en telemetría, con valores de ϵ que buena parte de la comunidad considera demasiado laxos — lo cual es exactamente el debate que el marco permite tener.
- Y llevó a **DP-SGD** (Abadi et al., 2016), que aplica la idea al entrenamiento de modelos: cada paso de gradiente con ruido calibrado.

10. Limitaciones

1. **El presupuesto se compone.** Cada consulta gasta privacidad, y administrar ese presupuesto a lo largo del tiempo es el problema práctico.
2. **Acotar la sensibilidad es difícil** fuera de los conteos. Para medias, máximos o consultas sobre grafos, es donde se cometen los errores.
3. **Elegir ϵ es una decisión de política**, no técnica, y el artículo no da criterio. Un ϵ laxo cumple la definición y no protege.
4. **Cuesta exactitud**, y en conjuntos pequeños o en subgrupos minoritarios el ruido puede dominar la señal — lo que afecta desproporcionadamente a quien menos representación tiene.
5. **Protege a individuos, no a grupos.** Que un colectivo entero sea identificable no lo impide.

11. Errores comunes

Error	Corrección
«Anonimizar es suficiente si se quitan los identificadores»	Se ha reidentificado a personas cruzando datos anónimos con otras fuentes. El problema es que la definición depende de qué más sepa el atacante.
«Publicar solo agregados protege la privacidad»	Dos consultas que difieren en una persona la revelan con certeza. En la miniatura, el ataque acierta el 100 % sin ruido.
«Decir «usamos privacidad diferencial» es una garantía»	Sin ϵ no dice nada. Con $\epsilon = 10$ el ataque sigue acertando el 99,3 % y la definición se cumple igualmente.
«La garantía vale para cualquier número de consultas»	Se compone: cada consulta gasta presupuesto. Sin declarar cuántas se permiten, la garantía es incompleta.
«Añadir ruido es siempre asumible»	Cuesta exactitud, y en subgrupos pequeños el ruido puede dominar la señal — perjudicando más a quien menos representación tiene.

12. Relación con trabajos anteriores

- **P134 La protección de la información (1975)** — proteger el acceso; aquí, proteger cuando el acceso ya está concedido.
- **P55 Teoría de la información (1948)** — la medida de cuánta información transporta una señal, que es lo que aquí se acota.

13. Relación con trabajos posteriores

- **Abadi et al. (2016)** — DP-SGD: entrenar modelos con privacidad diferencial.
doi:10.1145/2976749.2978318
- **P146 Aprendizaje federado (2017)** — la vía complementaria: no recoger los datos en vez de proteger lo publicado.
- **Dwork y Roth (2014)** — los fundamentos algorítmicos, en formato de libro.
doi:10.1561/04000000042

14. Notebook asociado

Qué implementa: el acierto de un ataque de diferenciación sin ruido y con ruido calibrado a varios valores de ϵ , junto al error que ese ruido introduce en la consulta legítima.

Qué NO implementa: se mide una sola consulta. La garantía se degrada al hacer muchas —el presupuesto se compone— y administrarlo es el problema práctico que la maqueta no toca.

```
ai-evolution paper-lab P143 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la definición de ϵ -privacidad diferencial.
Explicar	Explica qué es la sensibilidad de una consulta.
Aplicar	Ejecuta el notebook y compara el ataque con distintos ϵ .
Analizar	Analiza por qué la garantía no depende del conocimiento del atacante.
Evaluar	«Usamos privacidad diferencial». Evalúa qué falta para que esa frase signifique algo.
Crear	Busca un producto que la anuncie y comprueba si publica su ϵ y su presupuesto de consultas.

16. Autoevaluación

1. ¿Sobre qué se define la privacidad diferencial?
2. ¿Qué es la sensibilidad?
3. ¿Qué papel juega ϵ ?
4. ¿Protege un ϵ grande?
5. ¿Qué se paga?
6. ¿Qué ocurre con varias consultas?
7. ¿Protege a grupos?

17. Respuestas esperadas

1. Sobre el **mecanismo**, no sobre el dato. Exige que la salida cambie poco cuando se añade o quita una persona, con independencia de lo que el atacante sepa.
2. Cuánto puede cambiar el resultado de una consulta por una sola persona. Es la cantidad a la que se calibra el ruido.
3. Es la garantía. Acota cuánto puede cambiar la distribución de salida por una persona: más pequeño, más protección y más ruido.
4. No. Con $\epsilon = 10$ el ataque de la miniatura sigue acertando el 99,3 %, cumpliendo la definición formal. El valor concreto es la garantía.
5. Exactitud. Con $\epsilon = 0,1$ el error medio es 9,95 sobre un conteo de 249: un 4 % relativo.
6. El presupuesto se compone: cada consulta gasta privacidad. Declarar ϵ sin declarar cuántas consultas se permiten deja la garantía incompleta.

7. No. Protege a individuos. Que un colectivo entero sea identificable no lo impide, y eso es una limitación conocida de la definición.

18. Fuentes primarias

- Dwork, C., McSherry, F., Nissim, K. y Smith, A. (2006). *Calibrating Noise to Sensitivity in Private Data Analysis*. **TCC 2006**, 265–284. doi:10.1007/11681878_14 · consultado 2026-08-18.
- Dwork, C. y Roth, A. (2014). *The Algorithmic Foundations of Differential Privacy*. doi:10.1561/04000000042 · consultado 2026-08-18.
- Abadi, M. et al. (2016). *Deep Learning with Differential Privacy*. doi:10.1145/2976749.2978318 · consultado 2026-08-18.



Evaluación — P143 · Calibrar el ruido a la sensibilidad en el análisis privado de datos

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Calibrating Noise to Sensitivity in Private Data Analysis* (2006, TCC 2006, 265–284) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P143_privacidad_diferencial.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).