

P145

Superar el olvido catastrófico en redes neuronales

Overcoming catastrophic forgetting in neural networks

James Kirkpatrick, Razvan Pascanu, Neil Rabinowitz, Joel Veness, Guillaume Desjardins, Andrei A. Rusu, y otros ·
2017 · PNAS, 114(13), 3521–3526

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-18.

P145 — Superar el olvido catastrófico

Ruta de gobernanza · Si aprender lo nuevo mueve los pesos que sostenían lo viejo, la solución es frenar solo esos y dejar libres los demás.

Nivel: L3 · Motor: ewc · Notebook: P145_ewc.ipynb · Anexo: cálculo y gradientes

1. Identificación

Campo	Valor
Título original	Overcoming catastrophic forgetting in neural networks
Autoría	James Kirkpatrick, Razvan Pascanu, Neil Rabinowitz, Joel Veness, Guillaume Desjardins, Andrei A. Rusu y otros
Año	2017
Venue	PNAS, 114(13), 3521–3526
Fuente primaria	doi:10.1073/pnas.1611835114
Acceso	Abierto
Fecha de consulta	2026-08-18

2. Problema anterior

El olvido catastrófico llevaba casi treinta años documentado y sin remedio práctico.

La solución obvia —reentrenar con todos los datos anteriores— funciona y exige **conservarlos**, que es justo lo que a menudo no se puede: por volumen, por normativa de retención, o porque los datos eran de otra organización.

Y hay un problema conceptual detrás: no se sabía **qué** hay que preservar. Congelar toda la red impide aprender; dejarla libre borra lo anterior. Hacía falta una noción de «qué parte de la red sostiene lo que ya sabe».

3. Propuesta

Estimar **cuánto importa cada peso** para lo ya aprendido, y frenar solo esos.

La medida es la **información de Fisher**: cuánto cambia la verosimilitud de los datos de la tarea anterior al mover ese peso. Un peso con Fisher alto es crítico; uno con Fisher bajo se puede mover sin consecuencias.

Con eso, se añade a la pérdida una penalización cuadrática ponderada:

$$L(\theta) = L_B(\theta) + (\lambda/2) \cdot \sum_i F_i \cdot (\theta_i - \theta^*_{A,i})^2$$

↑ importancia del peso i para la tarea A

El nombre —consolidación elástica de pesos— viene de la analogía: cada peso importante queda unido a su valor anterior por un muelle cuya rigidez es su importancia.

4. Intuición sin fórmulas

Reorganizar una casa para que quepa algo nuevo. Puedes tener prohibido mover nada —y entonces no cabe— o mover lo que sea —y entonces pierdes cosas.

Lo razonable es marcar qué es imprescindible y moverlo poco, dejando libre todo lo demás. Y hay que marcarlo **antes** de empezar a reorganizar, porque después ya no se distingue.

Dónde deja de funcionar la analogía: en la casa los objetos son separables. En una red, un mismo peso participa en muchas cosas a la vez, y por eso la importancia es una cantidad continua y no una etiqueta.

5. Matemática mínima

$$F_i \approx E \left[\left(\partial \log p(y|x, \theta) / \partial \theta_i \right)^2 \right] \quad \leftarrow \text{información de Fisher, aproximación diagonal}$$

$$L(\theta) = L_B(\theta) + (\lambda/2) \cdot \sum_i F_i \cdot (\theta_i - \theta^*_{A,i})^2$$

La miniatura entrena en A , calcula la importancia y aprende B con distintos valores de λ :

λ	Exactitud en A	Exactitud en B	Media
0 (sin protección)	0,655	0,975	0,815
1	0,955	0,725	0,840
10	0,970	0,725	0,847
60	0,545	0,535	0,540

Tres lecturas. Con $\lambda = 10$, A se recupera de 0,655 a 0,97 —pero **B paga 0,25 puntos**. Es un intercambio explícito entre estabilidad y plasticidad, no una solución sin coste.


Con $\lambda = 60$, **ambas colapsan al azar**: la penalización domina al gradiente y no se aprende nada. λ no es un dial de seguridad que se sube.

Y la importancia no es uniforme —va de 0,303 a 1,000— pero en un clasificador lineal casi todos los pesos sirven al único hiperplano que hay, así que queda poco margen libre y B lo nota. En una red profunda hay muchísimo más margen, y ahí es donde el método luce.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A03 §5 · Comprobación numérica del gradiente	de dónde sale la aproximación de Fisher por el gradiente al cuadrado, y qué se pierde al usar solo la diagonal

6. Arquitectura o flujo



7. Qué observar en el paper original

- La **justificación bayesiana**: la penalización sale de aproximar la posterior de la tarea anterior por una gaussiana centrada en los pesos aprendidos, con precisión dada por Fisher.
- Los experimentos en **MNIST permutado** y en **juegos de Atari**, que es donde el método demuestra que escala a tareas de verdad.
- La **aproximación diagonal** de la matriz de Fisher, que ignora las correlaciones entre pesos. Es la simplificación que hace el método viable y también su límite.
- La analogía con la **consolidación sináptica** en neurociencia, que da nombre al método y que conviene leer como inspiración y no como evidencia.

8. Evidencia y resultados

Experimentos en tareas de clasificación secuenciales y en una secuencia de juegos de Atari, con comparación contra entrenamiento sin protección y contra reproducción de datos anteriores.

Publicado en PNAS, con revisión y código. La evidencia es sólida en las tareas evaluadas; trabajos posteriores señalan que los protocolos de evaluación de aprendizaje continuo eran demasiado favorables.

La miniatura usa un clasificador lineal y aproxima Fisher con el gradiente al cuadrado. El intercambio que exhibe es más duro que en una red profunda, precisamente porque no hay margen libre.

9. Impacto

- Reactivó el área del **aprendizaje continuo** y es su referencia más citada.
- La familia de métodos basados en regularización —inteligencia sináptica, MAS y otros— parte directamente de aquí.
- Es relevante en producción cada vez que un modelo se **ajusta por etapas**: cada ajuste es aprendizaje secuencial, y este método da una forma de acotar el daño.
- Y aporta un hábito: **medir la importancia antes de reentrenar** en lugar de descubrir después qué se rompió.

10. Limitaciones

1. **Con muchas tareas en secuencia**, las penalizaciones se acumulan y acaban congelando la red. Frena la degradación, no la elimina.
2. **La aproximación diagonal de Fisher** ignora las correlaciones entre pesos, que es donde vive buena parte de la estructura.
3. **Exige saber cuándo termina una tarea** y empieza otra. En un flujo continuo sin fronteras, hay que detectarlas.
4. **λ es un hiperparámetro delicado**: en la miniatura, $\lambda = 60$ colapsa ambas tareas.
5. **Kemker et al. (2018)** mostraron que los protocolos con los que se evaluaban estos métodos favorecían resultados optimistas.

11. Errores comunes

Error	Corrección
«EWC permite aprender la tarea nueva sin coste»	B paga 0,25 puntos por lo que A recupera. Es un intercambio explícito entre estabilidad y plasticidad.
«Cuanto mayor sea λ , mejor se conserva lo anterior»	Con $\lambda = 60$ ambas tareas caen al azar (0,545 y 0,535): la penalización domina al gradiente y no se aprende nada.
«La penalización frena todos los pesos por igual»	Es proporcional a la importancia de cada uno. Frenar uniformemente impediría aprender la tarea nueva sin proteger mejor la antigua.
«Resuelve el aprendizaje continuo»	Con muchas tareas las penalizaciones se acumulan y la red se congela. Frena la degradación, no la elimina.
«La importancia se puede calcular en cualquier momento»	Hay que calcularla al terminar la tarea, con sus datos. Después, los pesos ya se han movido y la medida no dice lo mismo.

12. Relación con trabajos anteriores

- **P142 Interferencia catastrófica (1989)** — el problema que este artículo ataca, planteado casi treinta años antes.
- **P02 Retropropagación (1986)** — la regla de actualización a la que se añade la penalización.
- **P40 Dropout (2014)** — otra forma de regularización, con un objetivo distinto.

13. Relación con trabajos posteriores

- **Zenke et al. (2017)** — inteligencia sináptica: la misma idea calculada en línea. [proceedings.mlr.press](https://proceedings.mlr.press/v70/zenke17a.html)
- **Kemker et al. (2018)** — qué miden realmente los métodos de aprendizaje continuo. [doi:10.1609/aaai.v32i1.11651](https://doi.org/10.1609/aaai.v32i1.11651)
- **P48 LoRA (2021)** — la vía arquitectónica: añadir capacidad nueva en vez de proteger la existente.

14. Notebook asociado

P145_ewc.ipynb

Qué implementa: la exactitud en las dos tareas para varios valores de λ , la importancia estimada de cada peso, y qué ocurre cuando λ es demasiado grande.

Qué NO implementa: es un clasificador lineal con Fisher aproximado por el gradiente al cuadrado. En una red profunda, la aproximación diagonal ignora correlaciones y hay mucho más margen libre.

```
ai-evolution paper-lab P145 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Escribe la pérdida con la penalización elástica.
Explicar	Explica qué mide la información de Fisher en este contexto.
Aplicar	Ejecuta el notebook y localiza el mejor λ .
Analizar	Analiza por qué λ demasiado grande colapsa ambas tareas.
Evaluar	«Subimos λ hasta que la tarea antigua dejó de degradarse». Evalúa la decisión.
Crear	Si mantienes un modelo que se reentrena, mide su rendimiento en una tarea antigua antes y después del último ajuste.

16. Autoevaluación

1. ¿Qué mide la información de Fisher aquí?
2. ¿Qué forma tiene la penalización?
3. ¿Es gratis conservar la tarea antigua?
4. ¿Qué pasa con λ muy grande?
5. ¿Cuándo hay que calcular la importancia?
6. ¿Resuelve el aprendizaje continuo?
7. ¿Cuál es la simplificación clave del método?

17. Respuestas esperadas

1. Cuánto cambia la verosimilitud de los datos de la tarea anterior al mover cada peso. Un peso con Fisher alto es crítico para lo ya aprendido.
2. Cuadrática y ponderada: tira de cada peso hacia su valor anterior con fuerza proporcional a su importancia. De ahí el nombre «elástica».
3. No. En la miniatura, B paga 0,25 puntos por lo que A recupera. Es un intercambio explícito entre estabilidad y plasticidad.
4. Ambas tareas colapsan al azar: con $\lambda = 60$, A queda en 0,545 y B en 0,535. La penalización domina al gradiente y no se aprende nada.
5. Al terminar la tarea y con sus datos. Después los pesos ya se han movido y la medida no dice lo mismo.
6. No. Con muchas tareas en secuencia, las penalizaciones se acumulan y la red se congela. Frena la degradación, no la elimina.
7. La aproximación diagonal de la matriz de Fisher: ignora las correlaciones entre pesos, lo que la hace viable y a la vez limita lo que puede capturar.

18. Fuentes primarias

- Kirkpatrick, J. et al. (2017). *Overcoming catastrophic forgetting in neural networks*. **PNAS**, 114(13), 3521–3526. doi:10.1073/pnas.1611835114 · consultado 2026-08-18.
- Zenke, F., Poole, B. y Ganguli, S. (2017). *Continual Learning Through Synaptic Intelligence*. proceedings.mlr.press · consultado 2026-08-18.
- Kemker, R. et al. (2018). *Measuring Catastrophic Forgetting in Neural Networks*. doi:10.1609/aaai.v32i1.11651 · consultado 2026-08-18.



Evaluación — P145 · Superar el olvido catastrófico en redes neuronales

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Overcoming catastrophic forgetting in neural networks* (2017, PNAS, 114(13), 3521–3526) · **Nivel:** L3

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P145_ewc.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).