

P146

Aprendizaje eficiente en comunicación de redes profundas con datos descentralizados

Communication-Efficient Learning of Deep Networks from Decentralized Data

H. Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, Blaise Agüera y Arcas · 2017 · AISTATS 2017,
PMLR 54, 1273–1282

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-18.

P146 — Aprendizaje federado

Ruta de gobernanza · Los datos más útiles son los más sensibles y viven en millones de dispositivos.
Promediar modelos en vez de recoger registros cambia el problema.

Nivel: L2 · **Motor:** federado · **Notebook:** P146_federado.ipynb · **Anexo:** complejidad y coste

1. Identificación

Campo	Valor
Título original	Communication-Efficient Learning of Deep Networks from Decentralized Data
Autoría	H. Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, Blaise Agüera y Arcas
Año	2017
Venue	AISTATS 2017, PMLR 54, 1273–1282
Fuente primaria	arXiv:1602.05629
Acceso	Abierto
Fecha de consulta	2026-08-18

2. Problema anterior

Los datos más valiosos para entrenar —lo que se escribe en el teclado, lo que se fotografía, lo que se dicta— son también los más sensibles, y viven en millones de dispositivos con conexión lenta, intermitente y a menudo medida.

Centralizarlos tiene dos costes. Uno de **comunicación**: subir todos esos datos es caro y lento. Y otro de **exposición**: una vez recogidos, existen en un sitio, con todo lo que eso implica de custodia, brechas y peticiones legales.

La pregunta era si se puede entrenar un modelo compartido sin que los datos se muevan.

3. Propuesta

Promediado federado, con una ronda que se repite:

1. el servidor manda el modelo actual a un subconjunto de clientes
 2. cada cliente entrena E épocas en LOCAL sobre sus propios datos
 3. cada cliente devuelve solo los PESOS resultantes
 4. el servidor los promedia ponderando por el tamaño de cada cliente

La idea clave es el paso 2: **más cómputo local a cambio de menos rondas**. En este escenario la comunicación es el recurso caro y el cómputo del dispositivo está ocioso, así que conviene gastar mucho de lo

segundo para ahorrar lo primero.

Y el diseño asume desde el principio lo que hace difícil el problema: clientes que aparecen y desaparecen, con cantidades de datos muy distintas y distribuciones no idénticas.

4. Intuición sin fórmulas

Un estudio médico en el que ningún hospital envía historiales. Cada uno analiza los suyos y manda solo las **conclusiones**; alguien las promedia y devuelve la conclusión conjunta, que cada hospital vuelve a refinar con sus datos.

Nadie ve los historiales de los demás y el resultado se parece al que se obtendría juntándolos.

Dónde deja de funcionar la analogía: las conclusiones también filtran. De los gradientes de un modelo se pueden reconstruir ejemplos de entrenamiento, así que «no salen datos» no es lo mismo que «no se filtra nada».

5. Matemática mínima

$$w_{t+1} = \sum_k (n_k / n) \cdot w_{t+1}^k$$

← promedio ponderado por tamaño de cliente

La miniatura usa 20 clientes con 60 registros cada uno y 12 rondas:

Distribución	Épocas locales	Exactitud final
homogénea	1	0,990
homogénea	5	0,993
heterogénea (una clase por cliente)	1	0,982
heterogénea	5	0,988

Se llega a **0,993 sin transmitir un solo registro**. Y más cómputo local acelera: en la ronda 1 se va de 0,975 con una época a 0,985 con cinco.


Un aviso sobre la heterogeneidad. Con cada cliente viendo una sola clase, la caída es de apenas 0,005. Esta maqueta **no reproduce** el fallo por heterogeneidad que documenta la literatura: con 20 clientes repartidos simétricamente y un modelo lineal, promediar cancela los sesgos locales. El fallo real aparece con redes profundas, participación desigual y clientes que no se compensan.

Lo que sí cambia de naturaleza es lo transmitido: **1 200 registros personales** frente a **240 vectores de 10 pesos**.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A05 §3 · La cuenta que decide el hardware: memoria	por qué aquí el recurso escaso es la comunicación y no el cómputo, y cómo eso invierte el diseño del algoritmo

6. Arquitectura o flujo



7. Qué observar en el paper original

- El **compromiso central**: épocas locales frente a rondas de comunicación. Es la palanca del método y el artículo la barre sistemáticamente.
- Los experimentos con **datos no idénticamente distribuidos**, que es donde el método sufre y donde el artículo es honesto sobre sus límites.
- El manejo de la **participación parcial**: solo un subconjunto de clientes responde en cada ronda, que es el caso realista con teléfonos.
- Que el artículo **no reclama privacidad**: reclama que los datos no se muevan, que es distinto y el propio texto lo distingue.

8. Evidencia y resultados

Experimentos sobre clasificación de imágenes y modelado de lenguaje, con barridos de épocas locales, fracción de clientes participantes y grado de heterogeneidad, midiendo rondas de comunicación hasta alcanzar un objetivo.

La métrica elegida —rondas hasta el objetivo— es la correcta para el problema, y es lo que distingue este trabajo de una simple demostración de que funciona.

La miniatura es regresión logística sobre datos sintéticos, y no reproduce la degradación por heterogeneidad. Eso está declarado en la propia evidencia del motor en lugar de sugerido.

9. Impacto

- Creó el área del **aprendizaje federado**, hoy con congresos, bibliotecas y despliegues reales.
- Está en producción en la predicción de teclado de Android, en modelos de voz y en varios consorcios médicos.
- Encaja con privacidad diferencial y agregación segura para formar una pila donde cada pieza cubre lo que las otras no.
- Y cambió el planteamiento por defecto: la pregunta «¿dónde centralizamos los datos?» pasó a tener una alternativa que antes no existía.

10. Limitaciones

1. **No da privacidad por sí solo.** De los gradientes se pueden reconstruir datos de entrenamiento; hace falta combinarlo con otras técnicas.
2. **La heterogeneidad degrada el promediado**, y es el problema práctico central del área. Esta maqueta no lo reproduce.
3. **Los clientes son poco fiables:** se caen, tienen capacidades muy distintas y participan de forma sesgada.
4. **Un cliente malicioso puede envenenar** el modelo enviando actualizaciones manipuladas, y el promedio simple no lo detecta.
5. **Depurar es difícilísimo:** no se pueden mirar los datos que causan un problema.

11. Errores comunes

Error	Corrección
«Aprendizaje federado es sinónimo de privacidad»	El artículo no lo reclama. De los gradientes se reconstruyen ejemplos; hace falta combinarlo con privacidad diferencial y agregación segura.
«Más rondas de comunicación es lo que hace falta»	Es al revés: la comunicación es el recurso caro. Se gasta cómputo local para reducir rondas, y esa es la palanca del método.
«Si los datos no salen, no hay riesgo»	El riesgo cambia de forma, no desaparece. Y aparece uno nuevo: un cliente puede envenenar el modelo con actualizaciones manipuladas.
«La heterogeneidad es un detalle»	Es el problema práctico central del área. Esta maqueta no lo reproduce y lo dice, precisamente para que no se lea como que no existe.
«Es equivalente a entrenar centralizado»	Se acerca en condiciones favorables. Con clientes desiguales, participación parcial y datos no idénticos, la diferencia es real.

12. Relación con trabajos anteriores

- **P143 Calibrar el ruido a la sensibilidad (2006)** — la pieza que aporta la garantía formal que este método no da.
- **P41 Adam (2014)** — la optimización local que cada cliente ejecuta.

- **P134 La protección de la información (1975)** — el principio de mecanismo mínimo compartido, del que esto es una aplicación literal.

13. Relación con trabajos posteriores

- **Kairouz et al. (2021)** — avances y problemas abiertos del aprendizaje federado. doi:10.1561/22000000083
- **Zhu et al. (2019)** — reconstruir datos de entrenamiento a partir de los gradientes. arXiv:1906.08935
- **P133 Colapso de modelo (2024)** — la otra restricción sobre de dónde pueden venir los datos.

14. Notebook asociado

P146_federado.ipynb

Qué implementa: la exactitud alcanzada promediando modelos sin transmitir datos, el efecto de gastar más cómputo local, y qué se transmite en cada enfoque.

Qué NO implementa: es regresión logística sobre datos sintéticos y **no reproduce** la degradación por heterogeneidad, que es el problema central del área. Tampoco modela caída de clientes ni actualizaciones envenenadas.

```
ai-evolution paper-lab P146 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Describe los cuatro pasos de una ronda federada.
Explicar	Explica por qué se gasta cómputo local para ahorrar comunicación.
Aplicar	Ejecuta el notebook y compara una y cinco épocas locales.
Analizar	Analiza por qué esta maqueta no muestra el fallo por heterogeneidad.
Evaluar	«Usamos aprendizaje federado, así que los datos están protegidos». Evalúa la afirmación.
Crear	Identifica datos que no puedas centralizar por normativa y estima si el promediado federado sería viable con su volumen y conectividad.

16. Autoevaluación

1. ¿Qué se transmite en cada ronda?
2. ¿Por qué más épocas locales ayudan?
3. ¿Da privacidad el método?
4. ¿Cuál es su problema práctico central?
5. ¿Por qué esta maqueta no lo muestra?
6. ¿Qué riesgo nuevo introduce?
7. ¿Con qué se combina en la práctica?

17. Respuestas esperadas

1. Solo los pesos del modelo entrenado en local, nunca los registros. El servidor los promedia ponderando por el tamaño de cada cliente.
2. Porque la comunicación es el recurso caro y el cómputo del dispositivo está ocioso. Más trabajo local significa menos rondas para llegar al mismo objetivo.
3. No por sí solo, y el artículo no lo reclama. De los gradientes se pueden reconstruir ejemplos de entrenamiento.
4. La heterogeneidad: cuando los clientes ven distribuciones muy distintas, sus modelos divergen y el promedio deja de ser un buen punto de encuentro.
5. Porque con 20 clientes repartidos simétricamente y un modelo lineal, promediar cancela los sesgos locales. El motor lo declara en su propia evidencia.
6. Un cliente malicioso puede enviar actualizaciones manipuladas para envenenar el modelo, y el promedio simple no lo detecta.
7. Con privacidad diferencial y agregación segura. Las tres piezas cubren cosas distintas y ninguna sustituye a las otras.

18. Fuentes primarias

- McMahan, H. B. et al. (2017). *Communication-Efficient Learning of Deep Networks from Decentralized Data*. **AISTATS 2017**, PMLR 54, 1273–1282. arxiv.org/abs/1602.05629 · consultado 2026-08-18.
- Kairouz, P. et al. (2021). *Advances and Open Problems in Federated Learning*. [doi:10.1561/22000000083](https://doi.org/10.1561/22000000083) · consultado 2026-08-18.
- Zhu, L., Liu, Z. y Han, S. (2019). *Deep Leakage from Gradients*. [arXiv:1906.08935](https://arxiv.org/abs/1906.08935) · consultado 2026-08-18.



Evaluación — P146 · Aprendizaje eficiente en comunicación de redes profundas con datos descentralizados

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Communication-Efficient Learning of Deep Networks from Decentralized Data* (2017, AISTATS 2017, PMLR 54, 1273–1282) · **Nivel:** L2

Parte A — Contexto histórico (20 pts)

1. (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
2. (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

3. (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
4. (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

5. (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

6. (10) Ejecuta `P146_federado.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
7. (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
8. (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

9. (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
10. (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).