

P147

Los modelos recurrentes del mundo facilitan la evolución de políticas

Recurrent World Models Facilitate Policy Evolution

David Ha, Jürgen Schmidhuber · 2018 · NeurIPS 2018 · arXiv:1803.10122

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-18.

P147 — Modelos del mundo

Ruta de gobernanza · Si el agente aprende un modelo del entorno, puede entrenar dentro de él. El problema es que encontrará sus grietas si le das tiempo.

Nivel: L3 · **Motor:** world_models · **Notebook:** P147_world_models.ipynb · **Anexo:** complejidad y coste

1. Identificación

Campo	Valor
Título original	Recurrent World Models Facilitate Policy Evolution
Autoría	David Ha, Jürgen Schmidhuber
Año	2018
Venue	NeurIPS 2018 · arXiv:1803.10122
Fuente primaria	arXiv:1803.10122
Acceso	Abierto
Fecha de consulta	2026-08-18

2. Problema anterior

Aprender por refuerzo exige millones de interacciones con el entorno. En simulación es caro; en un robot, inviable — cada interacción es tiempo real, desgaste y riesgo.

Y hay un desperdicio estructural: el agente pasa la mayor parte de esas interacciones **reaprendiendo cómo funciona el mundo**, no cómo actuar en él. La física de la escena, la dinámica del vehículo, qué pasa al pulsar un botón: todo eso se vuelve a inferir en cada episodio.

Si esa parte se pudiera aprender una vez y reutilizar, quedaría separada del problema de decidir.

3. Propuesta

Separar el agente en tres piezas con responsabilidades distintas:

V (visión)	: autocodificador variacional	→ comprime la observación a un vector
M (memoria)	: red recurrente mixta	→ predice el siguiente vector
C (controlador):	política diminuta	→ decide, mirando V y M

Lo llamativo es el tamaño: el controlador tiene **unos pocos centenares de parámetros** frente a los millones de V y M. Casi todo el modelo se dedica a entender el mundo, y muy poco a actuar en él.

Y la consecuencia que da nombre al artículo: como M predice el futuro, se puede **entrenar el controlador dentro de M** —lo que los autores llaman «soñar»— sin tocar el entorno ni una sola vez. La política resultante se transfiere al entorno real.

4. Intuición sin fórmulas

Aprenderse un circuito de carreras. Primero das vueltas mirando: dónde están las curvas, cómo responde el coche. Después puedes practicar la estrategia **mentalmente**, visualizando la vuelta, sin gastar gasolina.

Funciona en la medida en que tu visualización sea fiel. Si tu modelo mental exagera el agarre en una curva, la estrategia que practiques será justamente la que se aprovecha de ese error.

Dónde deja de funcionar la analogía: una persona sabe cuándo está imaginando y desconfía. Una política optimizada no desconfía: busca sistemáticamente el punto donde el modelo le promete más, y ese punto suele ser un error del modelo.

5. Matemática mínima

No hay formalismo nuevo: es una arquitectura. Lo medible es la **brecha** entre lo que el modelo promete y lo que el mundo entrega.

La miniatura busca la mejor política **dentro** del modelo y luego la ejecuta en el entorno real:

Error del modelo	Promete	Entrega	Brecha
0,00	-0,057	-0,057	0,000
0,05	-0,049	-0,058	0,009
0,15	-0,037	-0,059	0,022
0,30	-0,026	-0,063	0,037

Con un modelo exacto, entrenar dentro equivale a entrenar fuera. Según el modelo se desvía, la política se optimiza contra **sus errores** y la brecha crece de forma sistemática.

Y el ahorro es lo que justifica correr ese riesgo:


Dónde se busca la política	Interacciones reales
en el mundo	9 600
en el modelo	0

En un robot, esa diferencia es entre semanas y minutos.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A05 §8 · Checklist antes de creerte una cifra de rendimiento	por qué una cifra medida dentro del simulador no es una cifra de rendimiento

6. Arquitectura o flujo



7. Qué observar en el paper original

- El **tamaño del controlador**: unos centenares de parámetros. Que una política tan pequeña baste cuando la representación es buena es el resultado más provocador del artículo.
- El experimento de entrenar **enteramente dentro del sueño** y transferir al entorno real. Es la demostración de la tesis.
- Cómo los autores **detectan y frenan la explotación del modelo**: añadir incertidumbre —subir la temperatura del modelo— para que la política no pueda aprovechar sus grietas.
- La presentación **interactiva** del artículo, que permite manipular el modelo y ver sus predicciones. Es una forma de comunicar resultados que sigue siendo poco común.

8. Evidencia y resultados

Experimentos en dos entornos —conducción por vista superior y un juego en primera persona— con comparación contra los métodos del estado del arte de la época y con el experimento de entrenamiento íntegramente dentro del modelo.

La evidencia de la tesis principal es directa: una política entrenada sin tocar el entorno funciona en el entorno. Y el artículo documenta también cuándo eso falla.

La miniatura usa un entorno unidimensional determinista y un «modelo del mundo» que es una fórmula con un sesgo controlado. Sirve para exhibir la brecha; no reproduce ni la comprensión visual ni la predicción estocástica.

9. Impacto

- Reactivó el **aprendizaje por refuerzo con modelo** y abrió la línea que siguen Dreamer, DreamerV3 y los modelos del mundo actuales.
- La descomposición **visión / memoria / control** es hoy un patrón de diseño reconocible.
- La idea de **entrenar dentro de un modelo aprendido** es lo que hace viable la robótica moderna con aprendizaje, junto con la aleatorización de dominio.

- Y dejó una advertencia que se aplica mucho más allá: **una política optimizada explota los errores de su simulador**, y cuanto mejor sea la optimización, más los explota.

10. Limitaciones

1. **La política explota los errores del modelo**, y el problema empeora cuanto mejor sea la búsqueda. Es el fallo característico del aprendizaje con modelo.
2. **Los entornos evaluados son relativamente simples**. Escalar a entornos ricos exige modelos del mundo mucho mejores.
3. **El modelo se entrena con datos de una política aleatoria**, y por tanto solo conoce la parte del entorno que esa política visita.
4. **La compresión pierde información** que puede resultar relevante para la tarea, y el autocodificador no sabe cuál es.
5. **Añadir incertidumbre para frenar la explotación es un ajuste manual**, no un principio: hay que calibrarlo por entorno.

11. Errores comunes

Error	Corrección
«Si el modelo predice bien, la política transferirá bien»	Predice bien en promedio y mal en los rincones que la política busca. En la miniatura, con sesgo 0,3 el modelo promete $-0,026$ y el mundo entrega $-0,063$.
«Una búsqueda más potente da siempre una política mejor»	Dentro de un modelo imperfecto, una búsqueda mejor encuentra mejor sus grietas. Puede dar una política peor en el mundo real.
«El controlador tiene que ser grande»	Tiene unos centenares de parámetros. Casi toda la capacidad está en entender el mundo, no en decidir.
«La cifra del simulador es el rendimiento»	Es lo que el modelo promete. La única cifra que cuenta es la del entorno real, y la diferencia entre ambas es la brecha.
«Entrenar dentro del modelo elimina la necesidad de interactuar»	Elimina las interacciones de la búsqueda de política. El modelo hay que aprenderlo con interacciones reales, y su calidad las limita.

12. Relación con trabajos anteriores

- **P38 Autocodificador variacional (2013)** — la pieza que comprime la observación.
- **P03 LSTM (1997)** — la memoria recurrente que predice el futuro.
- **P26 DQN (2015)** — el aprendizaje por refuerzo sin modelo, con su coste en interacciones.

13. Relación con trabajos posteriores

- **Hafner et al. (2020)** — Dreamer: aprender comportamientos imaginando, con mejores modelos. [arXiv:1912.01603](https://arxiv.org/abs/1912.01603)
- **P103 Aleatorización de dominio (2017)** — la otra vía para cruzar el hueco entre simulación y realidad.
- **Sutton (1991)** — Dyna, la idea original de planificar con un modelo aprendido. [doi:10.1145/122344.122377](https://doi.org/10.1145/122344.122377)

14. Notebook asociado

P147_world_models.ipynb

Qué implementa: la brecha entre lo que promete un modelo del entorno y lo que entrega el entorno real según lo sesgado que esté el modelo, y el ahorro en interacciones reales.

Qué NO implementa: el entorno es unidimensional y determinista, y el «modelo del mundo» es una fórmula con un sesgo escalar. No hay compresión visual, ni predicción estocástica, ni el remedio de añadir incertidumbre.

```
ai-evolution paper-lab P147 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Describe las tres piezas de la arquitectura.
Explicar	Explica qué significa entrenar la política dentro del modelo.
Aplicar	Ejecuta el notebook y observa cómo crece la brecha con el sesgo.
Analizar	Analiza por qué una búsqueda más potente puede empeorar el resultado real.
Evaluar	«La política obtiene una recompensa excelente en el simulador». Evalúa la afirmación.
Crear	Si usas un simulador, mide la diferencia entre el rendimiento simulado y el real de una política tuya.

16. Autoevaluación

1. ¿Qué hace cada una de las tres piezas?
2. ¿Qué tamaño tiene el controlador?
3. ¿Qué significa «soñar» en este contexto?
4. ¿Qué es la brecha y de qué depende?
5. ¿Por qué una mejor búsqueda puede dar peor política?
6. ¿Qué remedio propone el artículo?
7. ¿Elimina la necesidad de interactuar con el entorno?

17. Respuestas esperadas

1. V comprime la observación en un vector, M predice el siguiente vector, y C decide la acción mirando los dos.
2. Unos pocos centenares de parámetros, frente a los millones de V y M. Casi toda la capacidad está en entender el mundo.
3. Entrenar el controlador dentro del modelo aprendido, sin tocar el entorno real ni una sola vez, y transferir después la política resultante.
4. La diferencia entre lo que el modelo promete y lo que el entorno entrega. Crece con el error del modelo: en la miniatura, de 0,000 a 0,037.

5. Porque optimiza contra el modelo, incluidas sus grietas. Cuanto mejor busca, mejor las encuentra, y esas grietas no existen en el mundo real.
6. Añadir incertidumbre al modelo —subir su temperatura— para que la política no pueda aprovechar sus errores. Es un ajuste manual, no un principio.
7. Elimina las interacciones de la búsqueda de política. El modelo hay que aprenderlo con interacciones reales, y su calidad limita todo lo demás.

18. Fuentes primarias

- Ha, D. y Schmidhuber, J. (2018). *Recurrent World Models Facilitate Policy Evolution*. **NeurIPS 2018**. arxiv.org/abs/1803.10122 · consultado 2026-08-18.
- Hafner, D. et al. (2020). *Dream to Control: Learning Behaviors by Latent Imagination*. [arXiv:1912.01603](https://arxiv.org/abs/1912.01603) · consultado 2026-08-18.
- Sutton, R. S. (1991). *Dyna, an Integrated Architecture for Learning, Planning, and Reacting*. [doi:10.1145/122344.122377](https://doi.org/10.1145/122344.122377) · consultado 2026-08-18.



Evaluación — P147 · Los modelos recurrentes del mundo facilitan la evolución de políticas

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Recurrent World Models Facilitate Policy Evolution* (2018, NeurIPS 2018 · arXiv:1803.10122) ·

Nivel: L3

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P147_world_models.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).