

P148

Cerrar la brecha de responsabilidad: un marco de auditoría algorítmica interna

Closing the AI Accountability Gap: Defining an End-to-End Framework for Internal Algorithmic Auditing

Inioluwa Deborah Raji, Andrew Smart, Rebecca N. White, Margaret Mitchell, Timnit Gebru, Ben Hutchinson, Jamila Smith-Loud, Daniel Theron, Parker Barnes · 2020 · FAT* '20, 33–44

Ficha pedagógica del Artificial Intelligence Evolution Program. No es el paper original: es una guía de lectura en español que enlaza a la fuente primaria. Consultado 2026-08-18.

P148 — Cerrar la brecha de responsabilidad

Ruta de gobernanza · «Faltan las etiquetas de subgrupo» es barato al recoger los datos e imposible después. Auditar al final es auditar cuando ya no se puede corregir.

Nivel: L1 · **Motor:** auditoria_interna · **Notebook:** P148_auditoria_interna.ipynb · **Anexo:** complejidad y coste

1. Identificación

Campo	Valor
Título original	<i>Closing the AI Accountability Gap: Defining an End-to-End Framework for Internal Algorithmic Auditing</i>
Autoría	Inioluwa Deborah Raji, Andrew Smart, Rebecca N. White, Margaret Mitchell, Timnit Gebru, Ben Hutchinson, Jamila Smith-Loud, Daniel Theron, Parker Barnes
Año	2020
Venue	FAT* '20, 33–44
Fuente primaria	doi:10.1145/3351095.3372873
Acceso	Abierto
Fecha de consulta	2026-08-18

2. Problema anterior

La auditoría algorítmica se hacía —cuando se hacía— **al final**, sobre un sistema ya construido, en forma de revisión ética antes del lanzamiento.

En ese punto los hallazgos importantes son incorregibles. Si faltan las etiquetas de subgrupo, no se puede desagregar la evaluación, y recogerlas exigiría rehacer el conjunto de datos. Si nadie definió a quién afecta el sistema, no hay contra qué comprobar nada.

Y hay un vacío más profundo: entre lo que una organización **dice** que hace y lo que se puede **comprobar** que hace no había ningún puente. Esa es la brecha de responsabilidad del título.

3. Propuesta

Convertir la auditoría en un **proceso con cinco etapas**, cada una con artefactos obligatorios que se producen mientras el sistema se construye:

alcance → correspondencia → recogida de artefactos → pruebas → reflexión

- **alcance:** declaración de caso de uso y de riesgos previstos;
- **correspondencia:** mapa de interesados y de responsabilidades;
- **recogida de artefactos:** hojas de datos y tarjetas de modelo;
- **pruebas:** resultados desagregados y pruebas adversarias;
- **reflexión:** análisis de riesgo y plan de mitigación.

La auditoría produce una **traza**, no un veredicto. Y el marco es explícito sobre lo que **no** hace: la audita quien la construye.

4. Intuición sin fórmulas

La documentación de un edificio. Los planos, los cálculos de estructura y los certificados de materiales se producen **mientras** se construye.

Un inspector que llega al final con el edificio en pie puede mirar las grietas visibles. Con los planos y los certificados puede comprobar si el forjado aguanta. Y si nadie los hizo, no hay forma de averiguarlo sin demoler.

Dónde deja de funcionar la analogía: al inspector de edificios lo paga alguien externo. La auditoría interna la hace la propia organización, y ese conflicto de interés es estructural — el artículo lo dice.

5. Matemática mínima

No hay formalismo: es un marco de proceso. Lo que se puede exhibir es el coste de llegar tarde.

La miniatura asigna a cada etapa un coste relativo de corregir un hallazgo ahí:

Etapas	Artefacto	Coste de cambiar
alcance	declaración de caso de uso y riesgos	1
correspondencia	mapa de interesados	2
recogida de artefactos	hojas de datos, tarjetas de modelo	5
pruebas	resultados desagregados	13
reflexión	análisis de riesgo y mitigación	34


Los mismos cinco hallazgos cuestan **55** si aparecen cuando corresponde y **170** si aparecen todos en la revisión final: **3,1× más**.

Y hay hallazgos que no es que cuesten más: es que **ya no se pueden corregir**. «Faltan las etiquetas de subgrupo» al recoger los datos es una tarde de trabajo; con el sistema construido, exige rehacer el conjunto.

[!TIP] **Puente matemático.** Esta sección da por sabido lo siguiente. Si algo no te suena, léelo primero: está explicado una sola vez, en un solo sitio, y sirve para todas las fichas.

Dónde	Qué necesitas de ahí
A05 §8 · Checklist antes de creerte una cifra de rendimiento	el mismo hábito llevado al proceso: qué artefactos hay que exigir antes de aceptar que un sistema es auditable

6. Arquitectura o flujo



7. Qué observar en el paper original

- Que el marco **exige artefactos y no opiniones**. Un auditor sin artefactos solo puede preguntar; con ellos, puede comprobar.
- La **matriz de fallos** que el artículo propone para la etapa de pruebas: qué puede salir mal, con qué probabilidad y con qué consecuencia.
- La sección sobre **lo que la auditoría interna no hace**, que es lo que le da credibilidad: no da cuenta pública, no tiene poder de veto y cubre lo que la organización decide mirar.
- Cómo el marco **encadena** los artefactos de trabajos anteriores —hojas de datos, tarjetas de modelo— en un proceso en vez de dejarlos como documentos sueltos.

8. Evidencia y resultados

El artículo propone el marco y lo ilustra con casos de aplicación, describiendo los artefactos y las plantillas concretas.

No hay evaluación de su efecto: no se mide si las organizaciones que lo aplican tienen menos incidentes. Es un marco propuesto y argumentado, no un resultado medido.

La miniatura asigna costes relativos por etapa que son **ilustrativos, no medidos**. Lo que el artículo sostiene cualitativamente es que corregir tarde es caro, no una escala concreta.

9. Impacto

- Es la referencia estándar de auditoría algorítmica interna, y su vocabulario —etapas, artefactos, traza— se ha incorporado a marcos de gobernanza.

- El **NIST AI Risk Management Framework (2023)** recoge la misma estructura de proceso con artefactos por etapa.
- El **Reglamento de IA de la Unión Europea** exige documentación técnica cuyo contenido se solapa fuertemente con estos artefactos.
- Y cierra el círculo del eje: tarjetas de modelo y hojas de datos dejan de ser documentos aislados y pasan a ser entregables de un proceso con responsables.

10. Limitaciones

1. **La audita quien la construye.** El conflicto de interés es estructural, y el artículo lo reconoce sin resolverlo.
2. **No da cuenta pública:** los resultados pueden quedarse dentro de la organización.
3. **No tiene poder de veto.** Si la dirección decide lanzar, la auditoría no lo impide.
4. **Cubre lo que la organización decide mirar**, así que un riesgo no contemplado en la etapa de alcance no aparece en ninguna etapa posterior.
5. **No hay evaluación de su efecto**, y sin incentivo externo —regulación, responsabilidad legal, presión pública— el marco no se adopta solo.

11. Errores comunes

Error	Corrección
«La revisión ética se hace antes del lanzamiento»	En ese punto los hallazgos importantes ya no se pueden corregir. Los mismos cinco hallazgos cuestan 3,1× más si aparecen todos al final.
«La auditoría interna sustituye a la externa»	El artículo es explícito: no da cuenta pública, no tiene poder de veto y la hace quien construye el sistema. Prepara el terreno, no sustituye.
«Auditar es emitir un juicio sobre el sistema»	Es producir una traza de artefactos comprobables. Un auditor sin artefactos solo puede preguntar.
«Si el sistema funciona bien, la auditoría es un trámite»	La auditoría comprueba si se puede saber cómo funciona y para quién falla. Eso es independiente de que funcione.
«Basta con tener tarjeta de modelo y hoja de datos»	Son dos de los artefactos. Sin el alcance, el mapa de interesados y el plan de mitigación, no hay proceso ni responsables.

12. Relación con trabajos anteriores

- **P114 Tarjetas de modelo (2019)** — uno de los artefactos que el marco exige.
- **P115 Hojas de datos (2021)** — el artefacto equivalente para los datos.
- **P112 ML Test Score (2017)** — la rúbrica de preparación técnica, complementaria a este proceso.

13. Relación con trabajos posteriores

- **NIST AI Risk Management Framework (2023)** — la misma estructura, en forma de norma.
doi:10.6028/NIST.AI.100-1
- **Costanza-Chock et al. (2022)** — cómo es realmente el ecosistema de auditoría de IA.
doi:10.1145/3531146.3533213

- **Reglamento de IA de la UE (2024)** — documentación técnica obligatoria para sistemas de alto riesgo.

14. Notebook asociado

P148_auditoria_interna.ipynb

Qué implementa: las cinco etapas con su artefacto, el coste relativo de corregir un hallazgo en cada una, y la diferencia entre auditar de forma continua o solo antes de lanzar.

Qué NO implementa: los costes relativos por etapa son ilustrativos, no medidos. Y el artículo tampoco evalúa el efecto del marco: no se mide si quien lo aplica tiene menos incidentes.

```
ai-evolution paper-lab P148 --seed 7
```

15. Actividades Bloom

Nivel	Actividad
Recordar	Enumera las cinco etapas y su artefacto.
Explicar	Explica por qué un hallazgo tardío puede ser incorregible.
Aplicar	Ejecuta el notebook y compara los dos costes.
Analizar	Analiza por qué exigir artefactos hace el proceso auditable.
Evaluar	«Hacemos revisión ética antes de cada lanzamiento». Evalúa el proceso.
Crear	Elige un sistema tuyo y comprueba cuáles de los cinco artefactos existen. Los que falten son tu deuda de auditoría.

16. Autoevaluación

1. ¿Cuáles son las cinco etapas?
2. ¿Qué produce la auditoría?
3. ¿Por qué importa el momento?
4. ¿Qué hallazgo es incorregible al final?
5. ¿Qué NO hace la auditoría interna?
6. ¿Por qué artefactos y no opiniones?
7. ¿Qué la conecta con el resto del eje?

17. Respuestas esperadas

1. Alcance, correspondencia, recogida de artefactos, pruebas y reflexión. Cada una produce un entregable concreto.
2. Una traza de artefactos comprobables, no un veredicto. Es lo que permite que alguien externo compruebe en vez de preguntar.

3. Porque corregir tarde es caro y a veces imposible. Los mismos cinco hallazgos cuestan 3,1× más si aparecen todos en la revisión final.
4. «Faltan las etiquetas de subgrupo». Al recoger los datos es una tarde; con el sistema construido, exige rehacer el conjunto de datos.
5. No da cuenta pública, no tiene poder de veto, la hace quien construye el sistema y cubre solo lo que la organización decide mirar.
6. Porque una opinión no se puede comprobar. Un auditor con hojas de datos y resultados desagregados puede verificar; sin ellos, solo puede preguntar.
7. Encadena las tarjetas de modelo y las hojas de datos en un proceso con responsables, en vez de dejarlas como documentos sueltos.

18. Fuentes primarias

- Raji, I. D. et al. (2020). *Closing the AI Accountability Gap*. **FAT*** '20, 33–44. doi:10.1145/3351095.3372873 · consultado 2026-08-18.
- NIST (2023). *AI Risk Management Framework 1.0*. doi:10.6028/NIST.AI.100-1 · consultado 2026-08-18.
- Costanza-Chock, S., Raji, I. D. y Buolamwini, J. (2022). *Who Audits the Auditors?* doi:10.1145/3531146.3533213 · consultado 2026-08-18.



Evaluación — P148 · Cerrar la brecha de responsabilidad: un marco de auditoría algorítmica interna

Generado por `python scripts/generate_papers.py`. Se evalúa comprensión histórica, lectura crítica e interpretación — no memorización de definiciones.

Paper: *Closing the AI Accountability Gap: Defining an End-to-End Framework for Internal Algorithmic Auditing* (2020, FAT '20, 33–44) · Nivel:* L1

Parte A — Contexto histórico (20 pts)

- (10) Describe el estado del arte **inmediatamente anterior** a este paper y por qué era insuficiente. No menciones la solución del paper en tu respuesta.
- (10) Nombra un trabajo anterior del que este paper depende y explica qué le tomó prestado.

Parte B — Lectura crítica (20 pts)

- (10) Localiza en el paper original una afirmación **cuantitativa** y reescríbela indicando tarea, dataset, métrica, línea base y condiciones. Cita la tabla o sección.
- (10) Identifica una idea que hoy se asocia a este paper pero que **apareció después**. Aporta la referencia posterior con año.

Parte C — Interpretación matemática (15 pts)

- (15) Explica la ecuación central con tus palabras y señala qué ocurre en un caso límite (valor 0, dimensión muy grande, secuencia muy larga... según corresponda).

Parte D — Implementación e interpretación (25 pts)

- (10) Ejecuta `P148_auditoria_interna.ipynb` con **tres semillas** y reporta qué varía y qué se mantiene.
- (10) Reproduce el anti-patrón de la sección 11 y explica por qué produce una conclusión errónea.
- (5) Aporta la corrección con su evidencia.

Parte E — Límites y transferencia (20 pts)

- (10) Escribe una limitación de la **miniatura** y una del **paper original**. No pueden ser la misma idea.
- (10) Conecta este hito con el siguiente de la ruta: ¿qué quedó sin resolver que motivó el paso siguiente?

Rúbrica

Nivel	Descripción
A — Excelente	Distingue hecho documentado, simplificación didáctica e inferencia propia. Cita fuentes primarias con sección o tabla. Sus límites son propios, no copiados.
B — Suficiente	Explica el mecanismo y ejecuta la miniatura correctamente, pero repite los límites de la ficha y cita de forma imprecisa.
C — Insuficiente	Describe el paper con narrativa retrospectiva, atribuye ideas posteriores, o presenta la salida de la miniatura como reproducción del experimento original.

Criterio automático de rechazo

Se devuelve sin nota cualquier entrega que:

- atribuya al paper resultados, métricas o autores que no aparecen en la fuente primaria;
- presente la ejecución del notebook como reproducción de los resultados del paper;
- cite un paper que no se abrió (se comprueba pidiendo el número de figura o tabla).